PRODUCT & TECHNICAL ROADMAP

AGENTFA

سند راهبردی محصول · نسخه ۱.۰

سند جامع محصول، کاربردها و ظرفیت توسعه فنی

از بازار ایجنت‌های تخصصی فارسی تا سیستم‌عامل کار دانشی

یک تصویر کامل از محصولی که امروز ساخته شده: از کاتالوگ و کیف پول و پرداخت، تا معماری، نقاط قوت، محدودیت‌های صادقانه و نقشه شش‌مرحله‌ای توسعه.

۲۶۴	۱۸	۱۶	۶+۱
ایجنت تخصصی	حوزه کاری	جدول داده	مرحله توسعه

تاریخ	مبنا	وضعیت
آبان ۱۴۰۵ · اکتبر ۲۰۲۶	commit ۱۰۴cfd۴	تحلیلی · مبتنی بر کد

درباره این سند

یک تصویر کامل از AgentFA

این سند برای تصمیم‌گیری محصولی و فنی نوشته شده است؛ نه برای تبلیغ. هرجا وضعیت امروز است، رفتار قابل ردیابی در کد یا مستندات است و هرجا هدف است، صریح به نقشه راه نسبت داده شده.

این سند چیست؟ یک تصویر کامل از محصولی که امروز ساخته شده، کاربردهای واقعی آن، نقاط قوت فنی که باید حفظ شوند، محدودیت‌های صادقانه، و مسیر چندمرحله‌ای بهبود فنی و کاربردی.

مبنای سند: بازبینی مخزن در commit `104cfd4`؛ کد `server/`، `agentfa-web/`، `api/`، `gateway/`؛ و مستندات `README.md`، `server/README.md`، `server/BILLING.md`، `gateway/README.md` و `docs/pitch/`.

قاعده خواندن: هرجا «امروز» نوشته شده، رفتار قابل ردیابی در کد یا مستندات است. هرجا «هدف» یا «پیشنهاد» است، بخشی از نقشه راه است، نه ادعای وضعیت فعلی. اعداد بازار، درآمد و اقتصاد واحد از اسناد ارائه نقل شده‌اند و باید پیش از استفاده بیرونی راستی‌آزمایی شوند.

۰۱

محصول و کاربرد

۲۶۴ ایجنت، ۱۸ حوزه، تجربه خرید و چت، کیف پول و پرداخت.

۰۲

معماری و قوت فنی

پول و مالکیت سمت سرور، تسویه امن، OTP، جداسازی کلید مدل.

۰۳

محدودیت‌ها

یک ارائه‌دهنده، نبود فایل/RAG/تیم/API و بدهی‌های اعتماد.

۰۴

نقشه توسعه

شش مرحله اصلی + فاز صفر، با دروازه عبور و معیار موفقیت.

نکته: این سند جایگزین قرارداد، پیشنهاد قیمت، مشاوره حقوقی یا حسابرسی فنی نیست. اعداد بازار و اقتصاد واحد از اسناد ارائه نقل شده‌اند و باید پیش از استفاده بیرونی راستی‌آزمایی شوند.

فهرست مطالب

مسیر خواندن

۱۹ بخش · فهرست قابل کلیک · پیمایش با نشانک‌های PDF

۰ خلاصه اجرایی ←

۱ این محصول چیست؟ ←

۲ تجربه و قابلیت‌های محصول ←

۳ کاربردها ←

۴ مدل کسب‌وکار ←

۵ معماری فنی ←

۶ نقاط قوت فنی ←

۷ محدودیت‌ها و بدهی فنی ←

۸ ظرفیت توسعه: نقشه ۶+۱ مرحله‌ای ←

۹ اولویت‌بندی و تصمیم‌های فنی ←

۱۰ سنجه‌ها ←

۱۱ ریسک‌ها ←

۱۲ نقشه ۹۰ روزه ←

۱۳ جمع‌بندی ←

الف سطح API ←

ب مدل داده ←

ج نقشه فایل‌ها ←

د واژه‌نامه ←

ه منابع، مفروضات و پرسش‌های باز ←

برای مطالعه سریع: خلاصه اجرایی، نقاط قوت فنی، و نقشه ۶+۱ مرحله‌ای.

۰ خلاصه اجرایی

AgentFA یک «بازار + موتور اجرا» برای ایجنت‌های تخصصی هوش مصنوعی فارسی است. کاربر یک متخصص آماده را انتخاب می‌کند، سه پیام رایگان آزمایش می‌کند، یک‌بار می‌خرد و برای همیشه در کتابخانه‌اش نگه می‌دارد؛ مصرف گفت‌وگو بر اساس توکن یا زمان از کیف پولش کسر می‌شود و همه‌چیز — پول، مالکیت، مصرف و کلید مدل — سمت سرور کنترل می‌شود.

موضوع	وضعیت امروز
کاتالوگ	۲۶۴ ایجنت در ۱۸ حوزه؛ هر ایجنت با پرسونا، توضیح، ویژگی‌ها و پرامپت‌های شروع
تجربه کاربر	فروشگاه، صفحه ایجنت، پیش‌نمایش سه‌پیامی، چت استریم، تاریخچه گفت‌وگو، داشبورد
اقتصاد	خرید یک‌باره ایجنت (۲۹ تا ۶۹ هزار تومان)، سه پلن، بسته توکن و زمان، کیف پول دوگانه
پرداخت	آداپتور زرین‌پال و استرایپ؛ تسویه فقط با تأیید درگاه؛ بازپرداخت ۷ روزه با تأیید ادمین
هویت	ورود با شماره موبایل و کد پیامکی؛ بدون رمز عبور؛ نشست httpOnly
زیرساخت	Vercel ؛ یک پروژهReact ۱۹ + Vite + Tailwind v۴؛ Fastify + Prisma + Postgres
کیفیت	تست واحد، smoke end-to-end، گیت‌های ۱۲ build، بررسی استقرار هر ۳۰ دقیقه
وضعیت تجاری	محصول فنی آماده؛ برای لانچ عمومی تجاری نیازمند مرچنت پرداخت، پنل پیامکی، پایش و پشتیبانی است
درآمد	بر اساس اسناد ارائه، پیش از لانچ عمومی و صفر؛ این سند ادعای درآمد ندارد

سه جمله‌ای که ماهیت محصول را می‌سازد:

۱. AgentFA «دسترسی به مدل» نمی‌فروشد؛ **متخصص آماده با فرایند و خروجی مشخص** می‌فروشد.

۲. درآمد آن به سه جریان گره خورده است: **فروش ایجنت، اشتراک/سهمیه، و مصرف**.

۳. مزیت دفاعی آن مدل زبانی نیست؛ **کاتالوگ بومی، زیرساخت تراکنش و مالکیت، و اعتماد قابل حسابرسی** است.

۱ این محصول چیست؟

۱.۱ تعریف یک‌خطی

AgentFA یک بازار و موتور اجرای ایجنت‌های تخصصی فارسی است: کاربر ایجنت می‌خرد، با پرسونای آن چت می‌کند، پاسخ را استریم می‌گیرد، و مصرفش را از کیف پول می‌پردازد.

۱.۲ چهار لایه محصول

AgentFA را نباید فقط «یک سایت فروش پرامپت» دید. محصول از چهار لایه تشکیل شده است:

لایه	چه چیزی هست	نمونه در کد
۱. محتوا	۲۶۴ پرسونای تخصصی در ۱۸ حوزه، با نام، توضیح، ویژگی، پرامپت شروع و متن کامل پرسونا	`design/*.md` ، `engineering/*.md` ، `server/content/seed.json`
۲. تجارت	قیمت، کیف پول، سهمیه، مالکیت، تراکنش، پرداخت، بازپرداخت	`server/src/wallet.ts` ، `server/src/payments/` ، `server/prisma/schema.prisma`
۳. اجرا	چت استریم با پرسونا، تاریخچه، اندازه‌گیری مصرف، قطع بودجه، ذخیره گفت‌وگو	`server/src/routes/chat.ts` ، `server/src/provider/stream.ts`
۴. عملیات	پنل ادمین، گزارش خطای مرورگر، سلامت سرویس، بررسی استقرار، گیت‌های کیفیت	`server/src/routes/admin.ts` ، `scripts/check-deploy.mjs` ، `agentfa-web/scripts/check-*.mjs`

نکته مهم: کاتالوگ پایه از پروژه متن‌باز `agency-agents` با مجوز MIT می‌آید. AgentFA لایه بومی‌سازی فارسی، تجاری‌سازی، پرداخت ریالی، کیف پول مصرفی و اجرای سمت سرور را روی آن ساخته است. این تفکیک برای درک محصول، مالکیت فکری و ریسک وابستگی مهم است.

۱.۳ مسئله‌ای که حل می‌کند

مدل عمومی، «کار عمومی» تحویل می‌دهد. برای کار تخصصی، کاربر امروز ناچار است:

۱. **خودش پرامپت‌نویس شود** — فرایند کار را بشناسد و آن را به مدل منتقل کند.
۲. **خروجی را بومی‌سازی کند** — پاسخ انگلیسی را ترجمه، بازنویسی و تنظیم کند.
۳. **دسترسی و پرداخت را دور بزند** — کارت ارزی، واسطه، هزینه و ریسک.
۴. **هر بار از صفر شروع کند** — کتابخانه، سابقه، مالکیت و تداوم وجود ندارد.

AgentFA این چهار شکاف را با «انتخاب متخصص به‌جای پرامپت‌نویسی»، «پرسونای فارسی»، «پرداخت ریالی» و «کتابخانه دائمی» پر می‌کند.

تفاوت با مدل عمومی در یک نگاه:

محور	مدل عمومی (ChatGPT و مشابه)	AgentFA
نقطه شروع	کاربر باید پرامپت بنویسد	کاربر متخصص آماده را انتخاب می‌کند
تخصص	عمومی؛ کیفیت به پرامپت کاربر وابسته است	پرسونا، فرایند و دامنه از پیش تعریف‌شده
زبان	پاسخ ممکن است انگلیسی/ناهمگون باشد	فارسی پیش‌فرض، RTL، لحن بومی
پرداخت	کارت ارزی/واسطه	ریالی، زرین‌پال، کیف پول توکن/زمان
مالکیت	اشتراک ابزار	خرید یک‌باره ایجنت + کتابخانه دائمی
مصرف	سقف اشتراک	کیف پول شفاف با ریز مصرف

۱.۴ ارزش پیشنهادی به تفکیک ذی‌نفع

ذی‌نفع	ارزش اصلی	معیار موفقیت
فرد متخصص	از ایده به پیش‌نویس قابل استفاده، بدون یادگیری پرامپت‌نویسی	زمان تحویل اولین خروجی، تکرار استفاده
تیم کوچک	ظرفیت تخصصی متغیر بدون استخدام نقش جدید	هزینه در برابر استخدام، سرعت تحویل
آژانس و استودیو	تولید بیشتر با تیم ثابت؛ تنوع تخصص	حاشیه پروژه، تعداد تحویل
سازمان	دسترسی کنترل‌شده به ایجنت‌های تخصصی با حساب‌دهی مصرف	انطباق، امنیت، گزارش مصرف
خالق محتوا/متخصص	عرضه پرسونا و کسب درآمد از فروش	درآمد خالق، کیفیت عرضه
تیم محصول AgentFA	جریان درآمد سه‌لایه و داده رفتار مصرف	حاشیه، ریزش، ARPU

۱.۵ مخاطبان هدف

- **دانش‌کاران و فریلنسرها:** توسعه‌دهنده، طراح، بازاریاب، تحلیلگر، مترجم، پژوهشگر.
- **تیم‌های کوچک و استارتاپ‌ها:** تیم ۲ تا ۲۰ نفره که نقش تخصصی خالی دارد.
- **آژانس‌ها و استودیوها:** بازاریابی، طراحی، تولید محتوا، توسعه.
- **سازمان‌های متوسط و بزرگ:** در فاز فعلی به‌صورت کاربران مستقل؛ در نقشه راه با تیم، SSO و قرارداد سازمانی.
- **خالقان و متخصصان حوزه:** در فاز فعلی مصرف‌کننده کاتالوگ؛ در نقشه راه عرضه‌کننده.
- **پژوهش و آموزش:** دانشجو، استاد، تیم تحقیق.

۱.۶ اعداد کلیدی (وضعیت snapshot)

شاخص	مقدار	توضیح
ایجنت‌ها	**۲۶۴**	فایل‌های پرسونا با frontmatter
حوزه‌ها	**۱۸**	دانشگاهی، طراحی، مهندسی، مالی، بازی‌سازی، GIS، سلامت، مارکتینگ، رسانه پرداختی، محصول، مدیریت پروژه، پژوهش، فروش، امنیت، رایانش فضایی، تخصصی، پشتیبانی، تست
جدول داده	**۱۶**	هویت، پول، محتوا، گفت‌وگو، عملیات
مسیر API	**۳۸**	۷ گروه اصلی (Auth، Catalog، Wallet، Agents، Chat، Payments، Admin) به‌همراه Health، Pricing، Account و Client errors
صفحه/مسیر SPA	**۱۷**	فروشگاه، ایجنت، چت، داشبورد، قیمت، حساب، ادمین، ورود/ثبت‌نام، بازگشت پرداخت، حقوقی، هدایت‌های ورود، ۴۰۴
قیمت ایجنت	**۲۹٬۰۰۰ تا ۶۹٬۰۰۰ تومان**	یک‌باره، دائمی
پلن‌ها	**۳**	رایگان، پایه ۲۹۰٬۰۰۰، حرفه‌ای ۹۹۰٬۰۰۰ تومان در ماه
تست و بررسی	**۹ فایل تست واحد API، ۷ فایل تست گیت‌وی، smoke، ۱۲ end-to-end بررسی استقرار**	جزئیات در بخش ۶

درباره اعداد: ۳۸ مسیر API از شمارش اعلان‌های مسیر در `server/src/routes/*.ts` به‌دست آمده است. تعداد تست‌ها بر اساس فایل‌های موجود است؛ اجرای واقعی آن‌ها در این محیط به‌دلیل محدودیت sandbox انجام نشد. برای گزارش بیرونی، خروجی CI را مبنا قرار دهید.

۱.۷ وضعیت امروز: چه چیزی آماده است و چه چیزی نه

آماده (قابل نمایش و استفاده):

- کاتالوگ ۲۶۴ ایجنتی و صفحه اختصاصی هر ایجنت.
- جست‌وجو، فیلتر حوزه، فیلتر قیمت، مرتب‌سازی و بارگذاری تدریجی.
- پیش‌نمایش سه‌پیامی روی ایجنت خریداری‌نشده.
- خرید یک‌باره، مالکیت دائمی، بازپرداخت ۷ روزه.
- چت استریم SSE با پرسونای سمت سرور، تاریخچه ذخیره‌شده و شمارش مصرف.
- کیف پول دوگانه (توکن/دقیقه)، سه پلن، بسته‌های توکن و زمان.
- ورود با شماره موبایل و کد پیامکی؛ تغییر شماره؛ حذف حساب.
- پنل ادمین: آمار، صف بازپرداخت، تنظیمات ارائه‌دهنده مدل، گزارش خطای مرورگر.
- دوزبانگی فارسی/انگلیسی با RTL کامل.

- پرداخت زرین‌پال/استرایپ در سطح آداپتور؛ پیامک کاوه‌نگار در سطح آداپتور.
- گیت‌های کیفیت build، تست واحد، smoke، بررسی استقرار.

هنوز نه (یا فقط در سطح زیرساخت):

- اتصال گیت‌وی چندارائه‌دهنده AI به مسیر چت فروشگاه؛ چت فعلی از یک ارائه‌دهنده فعال استفاده می‌کند.
- آپلود فایل، RAG، ابزار، حافظه بلندمدت و خروجی‌های فایلی.
- تیم، صندلی، کیف پول مشترک، SSO و نقش‌های سازمانی.
- برنامه خالقان، ساخت ایجنت بدون کد و API عمومی.
- رندر سمت سرور برای ۲۶۴ صفحه ایجنت (سئوی کامل).
- اپ موبایل بومی یا PWA کامل.
- دفتر هزینه واقعی و حاشیه به‌ازای هر گفت‌وگو.
- مانیتورینگ APM، هشدار خودکار و آزمون بار.

۲ تجربه و قابلیت‌های محصول

۲.۱ نقشه صفحه‌ها و قابلیت‌ها

مسیر	صفحه	چه کاری انجام می‌دهد	وضعیت
`/`	صفحه اصلی	جایگاه‌یابی، جست‌وجو، حوزه‌ها، ایجنت‌های ویژه، «چطور کار می‌کند»، سؤالات متداول	آماده
`/marketplace`	بازار	۲۶۴ ایجنت، جست‌وجو، فیلتر حوزه/قیمت، مرتب‌سازی (محبوب/ارزان/گران)، کشوی فیلتر موبایل، بارگذاری تدریجی	آماده
`/agent/:slug`	جزئیات ایجنت	توضیح بلند، ویژگی‌ها، پرامپت‌های شروع، قیمت، خرید، پیش‌نمایش، بازپرداخت، ایجنت‌های مرتبط	آماده
`/chat/:agentId`	چت	استریم پاسخ، پرسونا، تاریخچه گفت‌وگو، دانلود متن، پاک‌کردن، شمارش توکن/دقیقه، خرید توکن، ارتقای پلن	آماده
`/dashboard`	داشبورد	موجودی، ایجنت‌های من، پلن، نمودار مصرف ۳۰ روز، تراکنش‌ها	آماده
`/pricing`	قیمت‌ها	سه پلن، تخفیف سالانه ۲۰٪، بسته توکن و زمان	آماده

مسیر	صفحه	چه کاری انجام می‌دهد	وضعیت
`/login` و `/signup`	ورود/ثبت‌نام	شماره موبایل + کد پیامکی؛ یک مسیر مشترک برای کاربر جدید و بازگشتی	آماده
`/account`	حساب	تغییر شماره با تأیید پیامکی، حذف حساب	آماده
`/payment-required`	بازگشت پرداخت	نمایش وضعیت تراکنش و انتظار برای تسویه	آماده
`/admin`	ادمین	آمار، تنظیمات ارائه‌دهنده، تست اتصال، صف بازپرداخت، گزارش خطا	آماده (نقش ادمین)
`/privacy` ، `/terms` ، `/contact`	حقوقی	شرایط، حریم خصوصی، تماس	آماده
`*`	۴۰۴	۴۰۴ واقعی، نه پوسته SPA با کد ۲۰۰	آماده

۲.۲ سفر کاربر: از ورود تا بازپرداخت

```
۱. ورود با شماره موبایل
        │  کد پیامکی، یک‌بارمصرف، ۱۲۰ ثانیه
        ▼
۲. دریافت کیف پول رایگان (۵۰٬۰۰۰ توکن + ۶۰ دقیقه)
        │
        ▼
۳. جست‌وجو و مقایسه در بازار
        │  ایجنت، ۱۸ حوزه ۲۶۴
        ▼
۴. صفحه ایجنت: توضیح، ویژگی، پرامپت شروع، قیمت
        │
        ├── پیش‌نمایش رایگان: ۳ پیام (بدون خرید)
        │
        └── خرید: redirect به درگاه → callback مالکیت → تأییدشده
        ▼
۵. چت با پرسونای ایجنت
        │  SSE: delta / done / error
        │  اندازه‌گیری توکن یا زمان
        ▼
۶. ذخیره پیام + UsageEvent کسر از کیف پول + ثبت
        │
        ▼
۷. داشبورد: موجودی، مصرف، تراکنش‌ها، ایجنت‌های من
        │
        ▼
۸. در صورت نارضایتی: درخواست بازپرداخت ۷ روزه → تصمیم ادمین → ابطال مالکیت
```

۲.۳ کاتالوگ: ۲۶۴ ایجنت در ۱۸ حوزه

حوزه	تعداد	نمونه ایجنت‌ها	کاربرد نمونه
مهندسی	۶۴	Frontend Developer، Backend Architect، Code Reviewer، SRE، RAG Pipeline Engineer	ساخت و بازبینی نرم‌افزار، معماری، استقرار، داده
تخصصی	۵۹	Business Strategist، CFO، Legal Document Review، Recruitment Specialist، MCP Builder	نقش‌های کسب‌وکار، حقوقی، منابع انسانی، استراتژی
مارکتینگ	۳۶	SEO Specialist، Content Creator، Growth Hacker، Instagram Curator، PR Manager	کمپین، محتوا، سئو، شبکه اجتماعی
GIS	۱۳	Web GIS Developer، Spatial Data Scientist، Cartography Designer، BIM Specialist	نقشه، داده مکانی، سنجش از دور
امنیت	۱۲	Penetration Tester، AppSec Engineer، Cloud Security Architect، Compliance Auditor	آزمون نفوذ، امنیت ابری، انطباق
طراحی	۱۰	UI Designer، UX Researcher، Brand Guardian، UX Architect	رابط، تجربه کاربر، برند، سیستم طراحی
فروش	۹	Outbound Strategist، Deal Strategist، Pipeline Analyst، Proposal Strategist	پیشنهاد، تحلیل قیف، prospecting
تست	۹	API Tester، Accessibility Auditor، Performance Benchmarker، Test Automation Engineer	تست نرم‌افزار، دسترس‌پذیری، کارایی
رسانه پرداختی	۷	PPC Strategist، Paid Media Auditor، Tracking Specialist، Programmatic Buyer	تبلیغات پرداختی، اندازه‌گیری، ممیزی
مدیریت پروژه	۷	Project Shepherd، Jira Workflow Steward، Meeting Notes Specialist	تحویل پروژه، جریان کار، جلسات
دانشگاهی	۶	Historian، Psychologist، Statistician، Geographer	پژوهش، تحلیل، آموزش
بازی‌سازی	۶	Game Designer، Level Designer، Narrative Designer، Technical Artist	طراحی بازی، روایت، هنر فنی
رایانش فضایی	۶	visionOS Engineer، XR Immersive Developer، XR Interface Architect	رابط فضایی، visionOS، XR

حوزه	تعداد	نمونه ایجنت‌ها	کاربرد نمونه
پشتیبانی	۶	Support Responder، Analytics Reporter، Legal Compliance Checker	پاسخ‌گویی، گزارش، انطباق
مالی	۵	Financial Analyst، FP&A Analyst، Tax Strategist، Investment Researcher	تحلیل مالی، برنامه‌ریزی، مالیات
محصول	۵	Product Manager، Feedback Synthesizer، Sprint Prioritizer، Trend Researcher	کشف، اولویت‌بندی، بازخورد
سلامت	۳	Clinical Evidence Agent، Healthcare Innovation Strategist	شواهد بالینی، استراتژی سلامت
پژوهش	۱	Research Synthesist	ترکیب و جمع‌بندی پژوهش

تحلیل ترکیب کاتالوگ:

- **تمرکز زیاد روی مهندسی و تخصصی:** ۱۲۳ ایجنت از ۲۶۴ (۴۶٪) در این دو حوزه است. این برای فروش اولیه به مخاطب فنی خوب است، اما برای بازار عمومی‌تر باید تعادل ایجاد شود.
- **حوزه‌های نازک:** پژوهش (۱)، سلامت (۳)، مالی (۵)، محصول (۵). این حوزه‌ها برای فروش سازمانی جذاب‌اند اما عمق کافی ندارند.
- **فرصت بومی‌سازی:** بسیاری از پرسوناها از کورپوس انگلیسی آمده‌اند؛ کیفیت فارسی و تناسب با بازار ایران باید برای ۵۰ ایجنت پرتقاضا بازبینی شود.
- **نبود ایجنت‌های کاملاً ایرانی:** حقوق ایران، مالیات ایران، بورس تهران، ثبت شرکت، منابع انسانی ایرانی، آموزش و پرورش. اینها فرصت عرضه اختصاصی است.

> **هشدار اعتماد:** امتیاز (۴.۰ تا ۴.۹) و تعداد فروش (۲۰۰ تا ۲,۰۰۰) که در صفحه ایجنت دیده می‌شود، در snapshot فعلی از hash نام ایجنت تولید می‌شود و **social proof واقعی نیست**. تا راه‌اندازی نظرات خریدار واقعی، این اعداد باید حذف شوند یا صریحاً «نمونه» برچسب بخورند. جزئیات در بخش ۷.۱.

۲.۴ چت: قلب تجربه محصول

قابلیت	رفتار
پرسونا	متن کامل پرسونا فقط سمت سرور بارگذاری می‌شود؛ به مرورگر کاربر غیرمالک نمی‌رسد
استریم	پاسخ به‌صورت SSE با رویدادهای `delta` ، `done` ، `error`
تاریخچه	تا ۱۰ نوبت اخیر در پرامپت؛ تاریخچه کامل در دیتابیس
ذخیره‌سازی	هر گفت‌وگو با عنوان مشتق‌شده از اولین پیام؛ پیام‌ها با توکن/ثانیه/مدل

قابلیت	رفتار
پیش‌نمایش	۳ پاسخ رایگان؛ شمارنده سمت سرور، با پاک‌کردن مرورگر ریست نمی‌شود
بودجه	پیش‌نمایش: ۴٬۰۰۰ توکن / ۱۲۰ ثانیه؛ کاربر خریدار: مانده کیف پول
قطعی	اگر پاسخ از بودجه بیشتر شود، استریم قطع و `truncated` علامت می‌خورد
سکوت	اگر ارائه‌دهنده ۳۰ ثانیه ساکت بماند، درخواست قطع می‌شود
نمایش مصرف	زیر هر پیام: توکن و زمان؛ در نوار کنار: مصرف این گفت‌وگو و موجودی
ابزارها	دانلود متن گفت‌وگو، پاک‌کردن، کپی بلوک کد
محدودیت فعلی	پیوست فایل غیرفعال است؛ ابزار، RAG و حافظه بلندمدت وجود ندارد

۲.۵ کیف پول، پلن و قیمت

دو واحد مصرف:

- **توکن:** برای پاسخ‌های متنی؛ ۲ توکن به ازای هر تومان (۰.۵ تومان هر توکن).
- **زمان:** برای ایجنت‌هایی که با متر زمان کار می‌کنند؛ ۵۰۰ تومان هر دقیقه؛ حداقل ۶۰ ثانیه در هر پاسخ.

پلن‌ها:

پلن	سهمیه ماهانه	قیمت ماهانه	قیمت سالانه (۲۰٪ تخفیف)
رایگان	۵۰٬۰۰۰ توکن + ۶۰ دقیقه	۰	۰
پایه	۵۰۰٬۰۰۰ توکن + ۶۰۰ دقیقه	۲۹۰٬۰۰۰	۲٬۷۸۴٬۰۰۰
حرفه‌ای	۲٬۰۰۰٬۰۰۰ توکن + ۲٬۴۰۰ دقیقه	۹۹۰٬۰۰۰	۹٬۵۰۴٬۰۰۰

بسته‌های یک‌باره:

توکن	قیمت	زمان	قیمت
۱۰۰٬۰۰۰	۵۰٬۰۰۰	۶۰ دقیقه	۳۰٬۰۰۰
۳۰۰٬۰۰۰	۱۵۰٬۰۰۰	۳۰۰ دقیقه	۱۵۰٬۰۰۰
۱٬۰۰۰٬۰۰۰	۵۰۰٬۰۰۰	۱٬۲۰۰ دقیقه	۶۰۰٬۰۰۰

قواعد مهم:

- **پلن، مالکیت ایجنت نمی‌دهد.** پلن فقط سهمیه مصرف است؛ خرید ایجنت یک تراکنش جداگانه با مالکیت دائمی است. جمله «دسترسی به همه ایجنت‌ها» در کارت پلن رایگان باید به «مرور و خرید همه ایجنت‌ها» تغییر کند.
- قیمت‌ها فقط در `server/src/payments/pricing.ts` تعریف می‌شوند؛ UI همان لیست را از `GET /api/pricing` می‌خواند.

- کلاینت هرگز مبلغ را نمی‌فرستد؛ فقط «چه می‌خواهد» (توکن/دقیقه/پلن) را می‌فرستد.
- سهمیه ماهانه یک «پرکردن» است، نه سقف دوم؛ موجودی تنها سقف است.
- دوره ۳۰ روزه است و به‌صورت تنبل روی خواندن/کسر می‌چرخد؛ نیازی به cron نیست.
- پلن یعنی «سهمیه یک دوره»؛ اشتراک با تمدید خودکار و صورت‌حساب دوره‌ای وجود ندارد.

۲.۶ پرداخت، مالکیت و بازپرداخت

یک اینترفیس، دو آداپتور:

```
start() → referenceFromCallback() → verify() → [refund()]
```

مرحله	چه اتفاقی می‌افتد	تضمین
شروع	مبلغ از داده سرور محاسبه می‌شود؛ تراکنش `pending` با `orderId` ساخته می‌شود	کلاینت مبلغ را تعیین نمی‌کند
ریدایرکت	مرورگر به درگاه می‌رود؛ فقط URL و orderId به کلاینت می‌رسد	درگاه در `providerToken` ذخیره می‌شود handle
بازگشت	پیدا handle می‌آید؛ تراکنش از webhook یا callback می‌شود	`Status=OK` تنها کافی نیست
تأیید	زرین‌پال: verify با authority و مبلغ؛ استرایپ: HMAC روی بدنه خام	تأیید با خود درگاه
تسویه	`settleTransaction` مبلغ و handle را دوباره بررسی می‌کند	یک تراکنش دیتابیس
اعطا	مالکیت ایجنت یا شارژ کیف پول	فقط بعد از تسویه
بازپرداخت	درخواست → صف ادمین → تأیید/رد → refund درگاه → ابطال مالکیت	تکرارپذیر

تضمین‌های پول:

- callback تکراری `credited: false` برمی‌گرداند؛ دوبار اعتبار نمی‌دهد.
- `refId` و `providerToken` یکتا هستند؛ یک پرداخت نمی‌تواند دو سفارش را تسویه کند.
- تراکنش ناموفق با دلیل ذخیره می‌شود؛ رکورد معلق رها نمی‌شود.
- پرسونا تا تسویه قفل می‌ماند؛ پرداخت معلق محتوا را لو نمی‌دهد.
- بازپرداخت، «درخواست + تصمیم» است؛ هیچ پولی بدون تأیید برنمی‌گردد.
- خرید مجدد پس از بازپرداخت، تاریخچه را پاک نمی‌کند؛ `revokedAt` پاک و پرداخت تازه ثبت می‌شود.

۲.۷ حساب کاربری

- **تغییر شماره موبایل:** با کد پیامکی و حفظ همان `userId`؛ چون ورود فقط با شماره است، از دست دادن سیم‌کارت یعنی از دست دادن حساب و خریدها — این قابلیت یک نیاز امنیتی واقعی است.
- **حذف حساب:** با تأیید؛ داده‌های مرتبط با cascade حذف می‌شوند.
- **زبان:** فارسی پیش‌فرض؛ انگلیسی با تغییر جهت کامل RTL/LTR.
- **حریم خصوصی:** گزارش خطای مرورگر بدون شماره، IP یا شناسه نشست ذخیره می‌شود.

۲.۸ پنل ادمین

بخش	داده/عمل
آمار	تعداد کاربران، ایجنت‌ها، حوزه‌ها، خریدها، درآمد موفق، توکن مصرفی، بازپرداخت‌های در انتظار
ارائه‌دهنده مدل	آدرس، مدل، کلید (ماسک‌شده)، متر (توکن/زمان)، نرخ، دامنه ایجنت، فعال/غیرفعال، تست اتصال
بازپرداخت	صف درخواست‌ها؛ تأیید یا رد با دلیل
خطای مرورگر	گروه‌بندی‌شده با fingerprint، تعداد تکرار، ۲۴ ساعت اخیر، پیام پاک‌سازی‌شده

آنچه در پنل ادمین نیست: مدیریت کاربران، جست‌وجوی کاربر، تغییر پلن دستی، بن/آنبن، کد تخفیف، صورت‌حساب، گزارش تفصیلی درآمد. اینها در نقشه راه فاز ۳ و ۴ هستند.

۲.۹ دوزبانگی و RTL

- فارسی پیش‌فرض است و `dir` پیش از اولین رنگ‌آمیزی از `localStorage` اعمال می‌شود.
- هر دو دیکشنری در `agentfa-web/src/lib/i18n.tsx` هستند؛ کلید گمشده در build شکست می‌خورد.
- اعداد و مبالغ با `n()` و `toman()` قالب می‌شوند؛ متن خطا با «کد پایدار» ترجمه می‌شود، نه پیام خام.
- کاتالوگ انگلیسی است و `fa-agents.ts` نسخه فارسی را نگه می‌دارد؛ `check:catalog` از نشت فارسی به UI انگلیسی جلوگیری می‌کند.
- **باگ شناخته‌شده:** در نوار کنار چت، `agent.category` (فارسی) به‌جای `divisionLabel` نمایش داده می‌شود؛ در رابط انگلیسی متن فارسی دیده می‌شود. این نمونه‌ای است از اینکه گیت فعلی، «فیلد» را چک می‌کند نه «خروجی رندرشده» را.

۳ کاربردها

۳.۱ بر اساس مخاطب

مخاطب	مسئله	چگونه AgentFA کمک می‌کند	محدودیت امروز
توسعه‌دهنده	بازبینی کد، طراحی API، دیباگ، مستندسازی	ایجنت‌های Code Reviewer، Backend Architect، Technical Writer، SRE	خروجی متنی است؛ به مخزن وصل نیست
مدیر محصول	کشف نیاز، اولویت‌بندی، نوشتن PRD	Product Manager، Feedback Synthesizer، UX Researcher	فایل و داده ورودی ندارد
بازاریاب	کمپین، محتوا، سئو، تبلیغات	۳۶ ایجنت مارکتینگ + ۷ ایجنت رسانه پرداختی	اتصال به ابزار تبلیغاتی ندارد
طراح	رابط، تجربه، برند، سیستم طراحی	UI Designer، UX Architect، Brand Guardian	خروجی تصویری/فایل طراحی ندارد
تحلیلگر مالی	مدل مالی، بودجه، مالیات	Financial Analyst، FP&A، Tax Strategist	محاسبات ابزاری و اکسل زنده ندارد
تیم پشتیبانی	پاسخ‌گویی، گزارش، انطباق	Support Responder، Analytics Reporter	اتصال به تیکتینگ/CRM ندارد
پژوهشگر	مرور literature، جمع‌بندی	Historian، Research Synthesist، Statistician	و جست‌وجوی وب ندارد citation
آژانس	ظرفیت متغیر، تحویل سریع	ترکیب چند ایجنت در یک گردش‌کار	تیم مشترک و صورتحساب سازمانی ندارد
سازمان	کنترل، امنیت، حسابرسی	حساب کاربری، لاگ مصرف، پنل ادمین	نقش سازمانی و قرارداد ندارد، SSO

۳.۲ بر اساس کارکرد کسب‌وکار

کارکرد	ایجنت‌های پیشنهادی	خروجی معمول
استراتژی و رشد	Business Strategist، Growth Hacker، Pricing Analyst	تحلیل، فرضیه رشد، برنامه قیمت
بازاریابی و محتوا	Content Creator، SEO Specialist، Email Strategist، PR Manager	تقویم محتوا، متن کمپین، ایمیل، بیانیه
فروش	Outbound Strategist، Discovery Coach، Proposal Strategist	پیام prospecting، سؤال کشف، پیشنهاد
محصول و UX	Product Manager، UX Researcher، UI Designer، Feedback Synthesizer	یافته پژوهش، طرح رابط، PRD

کارکرد	ایجنت‌های پیشنهادی	خروجی معمول
مهندسی	Software Architect، Code Reviewer، RAG Engineer، SRE	طرح معماری، بازبینی، طرح استقرار
داده و تحلیل	Data Engineer، Data Visualization Engineer، Database Optimizer	طرح pipeline، نمودار، بهینه‌سازی کوئری
امنیت و انطباق	AppSec Engineer، Penetration Tester، Compliance Auditor	چک‌لیست، یافته، گزارش انطباق
مالی و حقوقی	Financial Analyst، Tax Strategist، Legal Document Review	تحلیل، یادداشت، بازبینی سند
پشتیبانی و عملیات	Support Responder، Operations Manager، Incident Responder	پاسخ، رویه، گزارش حادثه
حوزه‌های عمودی	سلامت، بازی‌سازی، رایانش فضایی، دانشگاهی، GIS	تخصص domain-specific

۳.۳ سناریوهای کامل

سناریو ۱ — کمپین محصول در یک روز

مسئله: تیم بازاریابی باید فردا کمپین محصول جدید را تحویل دهد.

۱. **PPC Strategist** ساختار حساب و تقسیم بودجه را می‌نویسد.

۲. **Search Query Analyst** فهرست negative keyword و intent را می‌سازد.

۳. **Ad Creative Strategist** سه نسخه RSA و متن سوشال می‌دهد.

۴. **Tracking Specialist** طرح رویدادهای GA۴/GTM را می‌نویسد.

۵. **Paid Media Auditor** طرح را از منظر هزینه و پوشش نقد می‌کند.

خروجی: یک بسته کمپین شامل ساختار، پیام، اندازه‌گیری و بازبینی. **آنچه AgentFA نمی‌دهد:** اجرای خودکار در Google Ads یا دسترسی به حساب تبلیغاتی.

سناریو ۲ — از مخزن ناآشنا تا اولین مشارکت

۱. **Codebase Onboarding Engineer** ساختار مخزن و مسیرهای کلیدی را توضیح می‌دهد.

۲. **Code Reviewer** ریسک‌های تغییر پیشنهادی را فهرست می‌کند.

۳. **Technical Writer** مستند تغییر و راهنمای مشارکت را می‌نویسد.

۴. **Git Workflow Master** استراتژی branching و پیام commit را پیشنهاد می‌دهد.

خروجی: نقشه ذهنی مخزن، بازبینی و مستند. **پیش‌نیاز:** کاربر باید کد یا توضیح آن را در چت بگذارد؛ اتصال مستقیم به GitHub وجود ندارد.

سناریو ۳ — از داده تا داشبورد

۱. **Data Engineer** طرح pipeline و مدل داده را می‌نویسد.
۲. **Database Optimizer** ایندکس و کوئری‌های کند را بررسی می‌کند.
۳. **Data Visualization Engineer** نوع نمودار و پالت رنگِ blind-safe را انتخاب می‌کند.
۴. **Analytics Reporter** narrative مدیریتی می‌سازد.

خروجی: طرح فنی + لایه بصری + روایت. **محدودیت:** فایل CSV/اکسل آپلود نمی‌شود؛ داده باید متنی توصیف شود.

سناریو ۴ — از بریف تا رابط

۱. **UX Researcher** سؤال پژوهش و معیار موفقیت را می‌نویسد.
۲. **UX Architect** ساختار اطلاعات و CSS system را می‌سازد.
۳. **UI Designer** کامپونت‌ها و حالت‌ها را تعریف می‌کند.
۴. **UI Finish-Gate Reviewer** از «رابط تکراری و بی‌هویت» جلوگیری می‌کند.
۵. **Accessibility Auditor** شکاف‌های WCAG را فهرست می‌کند.

خروجی: بریف پژوهش، معماری رابط، مشخصات کامپونت، چک‌لیست دسترس‌پذیری.

سناریو ۵ — آمادگی امنیتی پیش از انتشار

۱. **AppSec Engineer** مدل تهدید را می‌نویسد.
۲. **Penetration Tester** سناریوهای حمله را فهرست می‌کند.
۳. **Cloud Security Architect** پیکربندی ابری را بازبینی می‌کند.
۴. **Compliance Auditor** شکاف‌های انطباق را مستند می‌کند.
۵. **Incident Responder** runbook پاسخ به حادثه را می‌سازد.

خروجی: بسته آمادگی امنیتی. **هشدار:** این خروجی جایگزین آزمون نفوذ واقعی یا مشاور حقوقی نیست.

سناریو ۶ — تیم پشتیبانی چندزبانه

۱. **Support Responder** پاسخ‌های استاندارد را می‌سازد.
۲. **Language Translator** لحن فارسی/انگلیسی را تنظیم می‌کند.
۳. **Analytics Reporter** روند تیکت‌ها را خلاصه می‌کند.
۴. **Legal Compliance Checker** پاسخ‌های حساس را بازبینی می‌کند.

خروجی: پاسخ‌های آماده (macro)، راهنمای لحن، گزارش. **محدودیت:** اتصال به Zendesk/Intercom ندارد.

۳.۴ این محصول چه چیزی نیست؟

برای مدیریت انتظار، این مرزها را صریح بگویید:

- **یک چت‌بات عمومی نیست:** ایجنت‌ها پرسونا و دامنه مشخص دارند؛ مدل پایه عمومی است.
- **ارائه‌دهنده مدل نیست:** AgentFA مدل خودش را نمی‌سازد؛ لایه ارائه‌دهنده قابل تعویض است.
- **کارمند خودکار نیست:** امروز خروجی متنی/مشاوره‌ای می‌دهد؛ ابزار، فایل و اجرای واقعی ندارد.
- **جایگزین متخصص نیست:** در سلامت، حقوق، مالی و امنیت، خروجی باید با انسان متخصص بازبینی شود.
- **هنوز یک پلتفرم تیمی نیست:** صندلی، نقش سازمانی، SSO و کیف پول مشترک ندارد.
- **هنوز یک بازار خالقان نیست:** ساخت ایجنت، بازبینی و تسویه خالق وجود ندارد.
- **هنوز یک API عمومی نیست:** کلید API، webhook و SDK برای توسعه‌دهنده ندارد.

۴ مدل کسب‌وکار

۴.۱ سه جریان درآمد

جریان	مکانیزم	تکرار	حاشیه بالقوه
فروش ایجنت	خرید یک‌باره ۲۹ تا ۶۹ هزار تومان	یک‌بار به ازای هر ایجنت	بالا در فروش اول؛ اما بدون مصرف، درآمد تکرارشونده نیست
پلن/سهمیه	۲۹۰ یا ۹۹۰ هزار تومان در ماه؛ سالانه ٪۲۰ تخفیف	ماهانه/سالانه	متوسط؛ به مصرف واقعی گره خورده
مصرف	بسته توکن/زمان؛ کسر از کیف پول	متغیر	به هزینه استنتاج و قیمت‌گذاری بستگی دارد

۴.۲ اقتصاد واحد (برنامه، نه عملکرد)

اعداد زیر از اسناد ارائه پروژه نقل شده‌اند و «هدف/برنامه» هستند، نه داده حسابرسی‌شده:

شاخص	مقدار هدف
سالانه ARPU	۲.۰ تا ۲.۴ میلیون تومان
حاشیه ناخالص	٪۶۲
CAC	۲۵۰ هزار تومان
بازگشت CAC	۲.۴ ماه
LTV/CAC	۵ تا ۶
مشتری پرداخت‌کننده هدف (۱۸ ماه)	۱۰,۰۰۰
هدف ARR (۱۸ ماه)	۲۴ میلیارد تومان

نقد صادقانه: این اعداد به سه فرض وابسته‌اند: (۱) هزینه استنتاج پایین بماند، (۲) نرخ تبدیل پیش‌نمایش به خرید بالا باشد، (۳) ریزش با پلن سالانه و مالکیت کاهش یابد. هیچ‌کدام امروز با داده واقعی تأیید نشده‌اند. **اولین کار پس از لانچ، ساخت همان داده است.**

۴.۳ چرا مدل سه‌لایه منطقی است؟

- **فروش ایجنت** مانع ورود روانی پایین و «مالکیت» می‌سازد؛ کاربر احساس می‌کند چیزی خریده است.
- **پلن** مصرف سنگین را پیش‌پرداخت می‌کند و جریان نقدی پایدار می‌سازد.
- **مصرف** درآمد را به ارزش واقعی گره می‌زند و از سوءاستفاده نامحدود جلوگیری می‌کند.

ریسک اصلی مدل: اگر قیمت مصرف خیلی پایین باشد، مصرف سنگین حاشیه را می‌خورد؛ اگر خیلی بالا باشد، کاربر به مدل عمومی برمی‌گردد. بنابراین **دفتر هزینه واقعی و قیمت‌گذاری پویا** یک نیاز فنی است، نه لوکس.

۴.۴ کانال‌های رشد (از اسناد و قابل اجرا)

۱. **سئوی مرکب:** ۲۶۴ صفحه ایجنت + ۱۸ صفحه حوزه + محتوای مقایسه‌ای.
۲. **برنامه ارجاع:** لینک اختصاصی و توکن هدیه دوطرفه (در کد فعلی نیست؛ در نقشه راه).
۳. **برنامه خالقان:** عرضه پرسونا توسط متخصصان با تقسیم درآمد (در کد فعلی نیست).
۴. **فروش سازمانی:** قرارداد تیمی، آموزش، استقرار اختصاصی (نیازمند فاز ۳).
۵. **شراکت:** آژانس‌ها، آموزشگاه‌ها، پلتفرم‌های تفریحی/سوپراپ.

۴.۵ بازار و اندازه فرصت (از اسناد ارائه)

لایه	تعریف	ارزش سالانه هدف
TAM	۱۲ میلیون کاربر با انگیزه بهره‌وری دانشی	۲۱,۶۰۰ میلیارد تومان
SAM	۳ میلیون نفر با پرداخت آنلاین و مصرف AI	۷,۲۰۰ میلیارد تومان
SOM (سال ۳)	۷۰ هزار مشتری با کاتالوگ و کانال‌های محلی	۱۶۸ میلیارد تومان

> این اعداد از یک‌صفحه‌ای سرمایه‌گذار نقل شده‌اند و **برنامه/تخمین** هستند، نه داده مستقل. پیش از استفاده در ارائه رسمی، منبع و روش محاسبه باید بازبینی شود.

۵ معماری فنی

۵.۱ نمای کلی



۵.۲ پشته فناوری

لایه	فناوری	چرا انتخاب شده
فرانت	React ۱۹، Vite ۸، Tailwind v۴، React Router ۷	سرعت توسعه، HMR، باندل کوچک، RTL آسان
API	Fastify ۵، TypeScript، Zod	عملکرد بالا، طرح‌واره، مناسب سرورلس
داده	Postgres، Prisma ۶ با `engineType=client` و `@prisma/adapter-pg`	بدون باینری موتور، مناسب Vercel
نشست	کوکی httpOnly، توکن هش‌شده در DB	عدم افشای توکن در JS
مدل	ارائه‌دهنده سازگار با OpenAI، کلید رمزنگاری‌شده	تعویض ارائه‌دهنده با تنظیم
پرداخت	زرین‌پال/استرایپ، آداپتور مشترک	تعویض درگاه بدون تغییر محصول
پیامک	کاوه‌نگار	استاندارد بازار ایران
استقرار	Vercel: SPA + یک Function استاتیک	یک دامنه، بدون CORS، هزینه پایین
گیت‌وی AI	FastAPI + LiteLLM + Postgres/Redis	چندارائه‌دهنده، fallback، مخفی‌سازی هزینه

۵.۳ چرخه یک درخواست چت

```
POST /api/chat/stream
  { agentId, conversationId?, message, history[], lang }
        |
        ▼
۱. نشست ← کاربر                    (توکن هش‌شده، httpOnly کوکی)
۲. (۲۰/دقیقه، ۱۰۰/ساعت، ۵۰۰/روز)    محدودیت نرخ
۳. (یا ۳ پیام پیش‌نمایش رایگان)     مالکیت ایجنت
۴. تنظیمات ارائه‌دهنده + کیف پول
۵. (فقط سمت سرور)                  بارگذاری پرسونا
۶. تعیین بودجه                     (؛ خریدار: مانده‌ی‌پیش‌نمایش ۴٬۰۰۰ توکن/۱۲۰)
۷. فراخوانی مدل                    (نوبت تاریخچه ۱۰ + system)
۸. استریم SSE                      (delta / done / error)
۹. (توکن یا ثانیه)                 اندازه‌گیری مصرف
۱۰. کسر + ثبت                      (Wallet + UsageEvent + Message + Conversation)
```

نکات مهم:

- اگر پاسخ از بودجه بیشتر شود، استریم قطع و `truncated` علامت می‌خورد.
- قطعی سکوت ۳۰ ثانیه‌ای، درخواست را می‌بندد.
- کسر مصرف، پیام و شمارنده گفت‌وگو در یک تراکنش دیتابیس انجام می‌شود.
- پیام کاربر قبل از فراخوانی مدل ذخیره می‌شود؛ پیام دستیار بعد از پایان استریم.
- خطا به‌صورت رویداد `error` با کد پایدار به کلاینت می‌رسد.

۵.۴ مدل داده

گروه	جدول‌ها	نقش
هویت	`User` ، `Session` ، `LoginCode`	شماره موبایل، نشست، کد یک‌بارمصرف
پول	`Wallet` ، `Transaction` ، `Entitlement` ، `UsageEvent`	موجودی، تراکنش، مالکیت، ریز مصرف
محتوا	`Division` ، `Agent` ، `Persona` ، `PreviewUsage`	کاتالوگ، متن کامل، شمارنده پیش‌نمایش
گفت‌وگو	`Conversation` ، `Message`	تاریخچه و مصرف هر نوبت
عملیات	`ProviderConfig` ، `RateLimit` ، `ClientError`	تنظیم مدل، محدودیت نرخ، خطای مرورگر

قواعد قفل‌شده در schema:

- قیمت در `Agent.price` است؛ خرید قیمت را از سرور می‌خواند.
- `Entitlement` روی `(userId, agentId)` یکتاست؛ خرید دوباره رکورد را به‌روز می‌کند.
- `refId` و `providerToken` یکتا هستند؛ یک پرداخت دو سفارش را تسویه نمی‌کند.
- `Persona` جدا از `Agent` است تا متن کامل فقط برای مالک ارسال شود.
- `ClientError.fingerprint` یکتاست؛ گزارش تکراری یک upsert اتمی است.

۵.۵ خط تولید کاتالوگ

```
divisions.json + <division>/*.md
        │  frontmatter: name, description, vibe, emoji, color
        ▼
generate-catalog.mjs
        │
        ├── src/data/catalog.generated.ts    (۲۶۴ ایجنت، انگلیسی)
        ├── src/data/divisions.generated.ts  (۱۸ حوزه)
        └── src/data/featured.generated.ts   (۱۲ ایجنت صفحه اصلی)
        ▼
export-personas.mjs → server/content/seed.json
        ▼
seed-content.ts → Postgres (Agent + Persona + Division)
```

چرا این مهم است؟

- تولید در build انجام می‌شود، نه در زمان درخواست؛ برای سرورلس امن است.
- کاتالوگ انگلیسی و ترجمه فارسی جدا نگهداری می‌شود؛ گیت `check:catalog` از نشت زبان جلوگیری می‌کند.
- `check:i18n` کلیدهای گمشده و متن رندرشده در state را می‌گیرد.
- `check:routes` تضمین می‌کند هر مسیر SPA در `vercel.json` rewrite دارد.
- پرسونا در باندل مرورگر نیست؛ فقط در DB و سمت سرور.

۵.۶ استقرار و مسیر `/api`

یک پروژه Vercel:

مرحله	چه اتفاقی می‌افتد
Build	export seed → `prisma generate` → `migrate deploy` (فقط production) → `seed:content` → `tsc` → `vite build` → sitemap
Routing	`/api/(.*)` → `/api/index?__path=$1` با rewrite؛ handler پارامتر اضافه را حذف می‌کند
۴۰۴	لیست صریح مسیرهای SPA؛ بقیه ۴۰۴ واقعی
DB	Prisma `engineType=client` + `@prisma/adapter-pg` ؛ بدون باینری Rust
Function	۱۰۲۴ مگابایت، `maxDuration: 60`
پایش	`check-deploy.mjs` با ۱۲ بررسی، هر ۳۰ دقیقه
امنیت	CSP، `X-Frame-Options: DENY`، `nosniff`، `Referrer-Policy`، `Permissions-Policy`

دو تله‌ای که قبلاً تولید را شکسته و باید مستند بماند:

۱. `api/[...path].ts` **نگذارید.** در پروژه غیر Next، catch-all فقط یک segment را می‌گیرد؛ `/api/auth` می‌رسد اما `/api/auth/me` به edge می‌خورد و ۴۰۴ می‌شود. راه درست، rewrite است.

۲. **۴۰۴ را با پوسته SPA جواب ندهید.** همه مسیرها با ۲۰۰ یعنی لینک شکسته و سئوی خراب پنهان می‌شود. لیست صریح rewrite + `404.html` لازم است.

۵.۷ گیت‌وی AI: آماده، اما وصل‌نشده

ویژگی	وضعیت
دو مدل منطقی `agent-pro` / `agent-basic`	پیاده‌سازی شده
زنجیره‌ای fallback OpenAI → Anthropic → Gemini → Ollama	پیاده‌سازی شده
دو کلید به ازای هر ارائه‌دهنده، circuit breaker	پیاده‌سازی شده
مهلت ۲۵ ثانیه و بودجه timeout	پیاده‌سازی شده
مخفی‌سازی نام مدل/توکن/هزینه واقعی از مشتری	پیاده‌سازی شده و تست دارد
کسر اتمی اعتبار و ثبت مصرف	پیاده‌سازی شده
اتصال به چت فروشگاه	**انجام نشده**
پرداخت واقعی برای خرید اعتبار گیت‌وی	(بدون پردازنده) **stub**
استریم	**ندارد**

نتیجه: گیت‌وی یک دارایی فنی آماده است، اما امروز در مسیر درآمد فروشگاه نیست. اتصال آن، بزرگ‌ترین اهرم فنی فاز ۱ است.

۶ نقاط قوت فنی

۶.۱ جدول ارزیابی

قوت	چرا مهم است	شاهد	ارزیابی کیفی
پول و مالکیت سمت سرور	کلاینت نمی‌تواند قیمت، تخفیف یا مالکیت را جعل کند	`payments/pricing.ts`، schema، `agents.ts`	۵/۵
پرداخت قابل حسابرسی	تأیید با درگاه، تسویه تکرارپذیر، دلیل شکست	`checkout.ts`، `payments/*`	۴.۵/۵
احراز هویت بدون رمز	حذف رمز فراموش‌شده و نشتی؛ تجربه ساده	`lib/session.ts`، `auth/otp.ts`	۴.۵/۵

قوت	چرا مهم است	شاهد	ارزیابی کیفی
جداسازی کلید مدل	کلید هرگز به مرورگر نمی‌رسد	`stream.ts` ، `provider/crypto.ts`	۵/۵
مصرف قابل حسابرسی	هر پاسخ یک `UsageEvent` دارد	`routes/chat.ts` ، `wallet.ts`	۴.۵/۵
طراحی مناسب سرورلس	بدون فایل محلی، بدون cron واجب، بدون باینری موتور	`limiter.ts` ، `schema.prisma` ، `vercel.json`	۴.۵/۵
کاتالوگ به‌مثابه کد	۲۶۴ ایجنت قابل بازتولید و بررسی	`check-catalog.mjs` ، `generate-catalog.mjs`	۴.۵/۵
دوزبانگی و RTL	بازار فارسی، بازار انگلیسی	`check-i18n.mjs` ، `boot.js` ، `i18n.tsx`	۴/۵
پایش بیرونی استقرار	سبز به‌معنای سایت سالم نیست build	`scripts/check-deploy.mjs`	۳.۵/۵
تست و گیت	جلوگیری از رگرسیون پول و مسیر	`smoke.ts` ، `server/test/*`	۴/۵
آداپتورهای قابل تعویض	تغییر درگاه/پیامک بدون بازنویسی	`payments/index.ts` ، `sms/index.ts`	۴.۵/۵
آمادگی گیت‌وی چندمدلی	کاهش ریسک دسترسی به مدل	`gateway/`	۳.۵/۵ (چون وصل نیست)
عمق محصول	فایل، ابزار، حافظه، تیم	—	۲/۵
سئو و رشد	۲۶۴ صفحه قابل ایندکس	SPA + sitemap	۲.۵/۵
قابلیت سازمانی	نقش، صورتحساب، SSO	—	۱.۵/۵
اقتصاد خالقان/API	عرضه بیرونی و درآمد API	—	۱/۵

۶.۲ عمیق‌تر: هشت قوت کلیدی

۱) پول یک «دفتر» است، نه یک «شمارنده»

کیف پول فقط یک عدد نیست؛ هر حرکت یک `Transaction` با نوع، وضعیت، مبلغ، ارز، درگاه، `providerToken` ، `refId` ، دلیل شکست و زمان دارد. این طراحی سه چیز می‌دهد:

- **قابلیت حسابرسی:** می‌توان پرسید «این کاربر بابت چه چیزی، چه مبلغی، از کدام درگاه پرداخت کرد؟»
- **قابلیت بازیابی:** تراکنش معلق یا ناموفق رها نمی‌شود؛ دلیل دارد.
- **قابلیت تعویض درگاه:** درگاه در تراکنش ثبت می‌شود؛ تعویض PSP تاریخچه را بی‌معنا نمی‌کند.

۲) تسویه فقط با تأیید درگاه

الگوی رایج و خطرناک این است که به `Status=OK` در query string اعتماد شود. AgentFA این کار را نمی‌کند:

- زرین‌پال: authority و **مبلغ** دوباره به `verify.json` فرستاده می‌شود.
- استرایپ: HMAC روی بدنه خام بررسی می‌شود؛ به همین دلیل `req.rawBody` نگه داشته می‌شود.

- `settleTransaction` دوباره مبلغ و handle را بررسی می‌کند.
- `refId` و `providerToken` یکتا هستند؛ replay و double-credit بسته است.

این یکی از بالغ‌ترین بخش‌های کد است و باید همین‌طور بماند.

۳) ورود بدون رمز، با جزئیات امنیتی درست

- کد با HMAC-SHA۲۵۶ روی `phone:code` هش می‌شود؛ کد شش‌رقمی هرگز به‌صورت قابل بازیابی ذخیره نمی‌شود.
- فقط یک کد زنده برای هر شماره؛ درخواست جدید، کد قبلی را بازنشسته می‌کند.
- کد تأییدشده قبل از ساخت نشست مصرف می‌شود؛ replay = `code_expired` .
- پنج تلاش اشتباه کد را می‌سوزاند؛ مقایسه constant-time است.
- محدودیت نرخ بر شماره **و** IP؛ شمارش در Postgres، سازگار با سرورلس.
- شماره به E.۱۶۴ نرمال می‌شود و ارقام فارسی/عربی/لاتین را می‌خواند؛ `۰۹۱۲…` ، `0912-…` و `+98…` یک حساب‌اند.
- `otp/start` وجود حساب را لو نمی‌دهد؛ شماره ناشناس هم کد می‌گیرد.
- اگر ارسال پیامک شکست بخورد، رکورد کد حذف می‌شود؛ «ورود معلق» نمی‌ماند.

۴) کلید مدل، مرز اعتماد است

کلید ارائه‌دهنده با AES-۲۵۶-GCM رمزنگاری می‌شود؛ IV و tag همراه ciphertext ذخیره می‌شوند؛ کلید فقط سمت سرور رمزگشایی می‌شود. پنل ادمین فقط نسخه ماسک‌شده (`sk-ab…9f2c`) را می‌بیند. حتی خطاهای ارائه‌دهنده به کدهای پایدار (`invalid_key` ، `rate_limited` ، `timeout`) تبدیل می‌شوند تا URL و جزئیات به کلاینت نشت نکند.

۵) مصرف، اتمی و قابل توضیح

- کسر مصرف در `prisma.$transaction` انجام می‌شود: خواندن کیف پول، بررسی کفایت، کاهش، ثبت `UsageEvent` .
- دوره ۳۰ روزه به‌صورت تنبل می‌چرخد؛ `balance = max(balance, allowance)` سهمیه را برمی‌گرداند و خرید اضافه را حفظ می‌کند.
- بودجه پاسخ از مانده کیف پول می‌آید؛ پاسخ بیش از بودجه قطع می‌شود.
- پیش‌نمایش، شمارنده سمت سرور دارد؛ با پاک‌کردن مرورگر ریست نمی‌شود.
- اگر ارائه‌دهنده `usage.total_tokens` ندهد، تخمین فارسی‌آگاه (۲ کاراکتر/توکن) با پرچم `estimated` ثبت می‌شود.

۶) سرورلس بدون «دروغ» معماری

بسیاری از پروژه‌ها روی Vercel می‌شکنند چون به فایل محلی، cron، SQLite یا باینری موتور Prisma وابسته‌اند. AgentFA این وابستگی‌ها را حذف کرده است:

- Postgres تنها منبع state است؛ هیچ فایلی در زمان درخواست خوانده نمی‌شود.
- `engineType = "client"` و `@prisma/adapter-pg` باینری `rhel-openssl-3.0.x` را حذف می‌کند.
- کاتالوگ در build تولید و seed می‌شود، نه در request.
- دوره کیف پول تنبل می‌چرخد؛ cron لازم نیست.

- محدودیت نرخ در Postgres است، چون اتصال Redis در سرورلس دوام ندارد.
- `attachDatabasePool` اتصال‌های بیکار را قبل از suspend آزاد می‌کند.

۷) کاتالوگ به‌مثابه کد، نه محتوای دستی

- `divisions.json` منبع حقیقت حوزه‌هاست.
- frontmatter هر فایل، نام/توضیح/ویژگی/پرامپت را می‌دهد.
- generator، کاتالوگ و آمار حوزه‌ها را می‌سازد؛ `featured` بر اساس seed.
- `export-personas.mjs` متن کامل را به seed سرور می‌برد.
- `check:catalog` از نشت فارسی به UI انگلیسی جلوگیری می‌کند.
- `scripts/check-divisions.sh` (در CI) از ناهم‌خوانی دایرکتوری‌ها با `divisions.json` جلوگیری می‌کند.

مزیت: افزودن یک ایجنت، یک فایل Markdown + یک build است، نه یک migration دستی.

۸) قابلیت عملیات: «build سبز» کافی نیست

- `check-deploy.mjs` از بیرون بررسی می‌کند: پوسته SPA، مسیرهای تودرتو `/api`، سلامت، قیمت، sitemap، robots، کش دارایی، هدرهای امنیتی و ۴۰۴ واقعی.
- CI هر ۳۰ دقیقه آن را اجرا می‌کند؛ چون یک بار سایت ۱۰ روز خراب ماند و هیچ‌کس نفهمید.
- `ClientError` خطای مرورگر را با fingerprint گروه‌بندی می‌کند؛ هزار گزارش یک ردیف می‌شود.
- پیام خطا قبل از ذخیره پاک‌سازی می‌شود؛ شماره/IP/نشست ذخیره نمی‌شود.

۶.۳ مزیت دفاعی واقعی

مدل زبانی، مزیت دفاعی نیست؛ قابل تعویض است. مزیت AgentFA سه چیز است:

۱. **کاتالوگ بومی و تجربه فارسی:** ۲۶۴ پرسونا، ۱۸ حوزه، لحن و فرایند فارسی. کپی‌کردن آن آسان نیست، اما غیرممکن هم نیست؛ کیفیت و بازبینی، دفاع واقعی است.

۲. **زیرساخت تراکنش و مالکیت:** پول، پرداخت، بازپرداخت، حسابرسی، مالکیت دائمی. این لایه، اعتماد می‌سازد و کپی‌کردنش زمان‌بر است.

۳. **داده رفتار مصرف:** کدام ایجنت، کدام کاربر، چه مصرفی، چه خروجی‌ای. این داده، قیمت‌گذاری، مسیریابی مدل و توصیه را بهتر می‌کند.

۷ محدودیت‌ها و بدهی فنی

۷.۱ ثبت بدهی فنی

اولویت	محدودیت	اثر	شاهد/توضیح
اعتماد — P۰	امتیاز و تعداد فروش کاتالوگ، ساختگی است	اعتماد کاربر و اعتبار برند را خراب می‌کند	`generate-catalog.mjs` : `rating = 4 + seed % 10 / 10` ، `sales = 200 + seed % 1800`
اعتماد — P۰	متن فارسی قیمت‌ها می‌گوید «پرداخت‌ها در نسخه MVP شبیه‌سازی می‌شوند»	با پرداخت واقعی در تناقض است	`pricing.body` ، `i18n.tsx`
اعتماد — P۰	پلن رایگان می‌گوید «دسترسی به همه ایجنت‌های فروشگاه»	با gating مالکیت در تناقض است	`plan.free.f1`
تجربه — P۰	دسته‌بندی در نوار کنار چت در UI انگلیسی فارسی نشان می‌دهد	نقض دوزبانگی	`Chat.tsx` خط ۵۱۴: `agent.category`
لانچ — P۰	مرچنت پرداخت و پنل پیامکی production	بدون آن، لانچ تجاری ممکن نیست	`PAYMENT_PROVIDER` ، `SMS_PROVIDER`
لانچ — P۰	پایش APM/هشدار/بکاپ/بازیابی	خرابی بی‌صدا	فقط `ClientError` و deploy check
لانچ — P۰	تست E۲E مرورگر و آزمون بار	رگرسیون UX و ظرفیت نامعلوم	فقط API smoke است
عمق — P۱	یک ارائه‌دهنده فعال در چت	قطعی ارائه‌دهنده = قطعی چت	`activeProvider()` جدیدترین ارائه‌دهنده فعال را می‌گیرد؛ fallback چندپروفایلی ندارد
عمق — P۱	بدون فایل/RAG/ابزار/حافظه	ایجنت «مشاور متنی» است، نه «کارگزار»	دکمه پیوست غیرفعال
عمق — P۱	تاریخچه فقط ۱۰ نوبت	گفت‌وگوی بلند، حافظه را از دست می‌دهد	`HISTORY_LIMIT = 10`
اقتصاد — P۱	دفتر هزینه واقعی و حاشیه هر گفت‌وگو نیست	قیمت‌گذاری کورکورانه	`ProviderConfig` نرخ دارد اما مصرف را به هزینه واقعی نگاشت نمی‌کند
مقیاس — P۱	سقف ۶۰ ثانیه Function	پاسخ طولانی/استریم قطع می‌شود	`vercel.json`
مقیاس — P۱	کاتالوگ و صفحه ایجنت سمت کلاینت رندر می‌شود	سئوی ۲۶۴ صفحه ضعیف	SPA + sitemap
مقیاس — P۱	صف/کار پس‌زمینه ندارد	ایمیل، گزارش، همگام‌سازی، پردازش فایل	فقط request/response
مقیاس — P۱	Rate limit در Postgres	در ترافیک بالا، فشار روی DB	اختیاری Redis

اولویت	محدودیت	اثر	شاهد/توضیح
مقیاس — P۲	جست‌وجو و فیلتر بازار سمت کلاینت است	برای ۲۶۴ ایجنت کافی است؛ در ۱۰٬۰۰۰+ ایجنت کند و بی‌ارتباط می‌شود	`Marketplace` روی آرایه کامل فیلتر می‌کند
پلتفرم — P۲	تیم/سازمان/SSO/RBAC نیست	فروش B۲B محدود	`Role.user/admin` فقط schema
پلتفرم — P۲	فاکتور رسمی/VAT/صورت‌حساب دوره‌ای نیست	مانع خرید سازمانی و مالی	فقط تراکنش خام
پلتفرم — P۲	برنامه خالقان و ساخت ایجنت نیست	عرضه مقیاس‌پذیر ندارد	—
پلتفرم — P۲	API عمومی/کلید/webhook/SDK نیست	توسعه‌دهنده نمی‌تواند بسازد	—
پلتفرم — P۲	اپ موبایل/PWA کامل نیست	تجربه موبایل محدود به وب	—
کیفیت — P۲	بازبینی/نظرات واقعی خریدار نیست	social proof واقعی ندارد	ساختگی rating/sales
کیفیت — P۲	نسخه‌بندی پرسونا و eval خودکار نیست	تغییر پرسونا می‌تواند کیفیت را بی‌صدا خراب کند	—
کیفیت — P۲	محتوا نیست guardrail و moderation	ریسک خروجی نامناسب	—
منطقه — P۲	فقط فارسی/انگلیسی	بازار عربی/منطقه‌ای ناقص	—

۷.۲ سه ریسک پنهان که باید همین امروز دیده شوند

۱. **Social proof ساختگی:** امتیاز ۴.۰ تا ۴.۹ و فروش ۲۰۰ تا ۲٬۰۰۰ از hash تولید می‌شود. این برای دمو خوب است، برای فروش واقعی سم است. یا حذف شود، یا برچسب «نمونه» بخورد، یا با نظرات خریدار واقعی جایگزین شود.

۲. **تناقض کپی و رفتار:** «پرداخت شبیه‌سازی می‌شود» و «دسترسی به همه ایجنت‌ها» با کد فعلی نمی‌خواند. این‌ها شکایت و بازپرداخت می‌سازند.

۳. **حسابرسی هزینه:** نرخ‌های `tomanPer1kTokens` و `tomanPerMinute` در تنظیمات ارائه‌دهنده ذخیره می‌شوند، اما کسر کیف پول بر اساس توکن/ثانیه است، نه هزینه واقعی. بدون دفتر هزینه، نمی‌دانید کدام ایجنت حاشیه مثبت دارد.

۸ ظرفیت توسعه: نقشه ۶+۱ مرحله‌ای

۸.۰ ظرفیت‌های ساختاری و دارایی‌های آماده

پیش از فازبندی، باید دید **چه چیزی در معماری امروز، توسعه را ارزان می‌کند**:

ظرفیت ساختاری	چرا توسعه را آسان می‌کند
۱۶ جدول با مرزهای روشن	افزودن `Organization` ، `File` ، `Review` ، `ApiKey` بدون بازطراحی هسته ممکن است
الگوی آداپتور	پرداخت، پیامک و مدل پشت اینترفیس‌اند؛ ارائه‌دهنده جدید = یک فایل + یک ثبت
کاتالوگ تولیدشده	۲۶۴ به ۱٬۰۰۰+ ایجنت بدون migration دستی و با همان گیت‌ها
تفکیک SPA/API	امکان افزودن SSR، اپ موبایل یا API عمومی بدون بازنویسی منطق
و استریم SSE	بستر طبیعی برای RAG، ابزار، artifact و پاسخ تدریجی
گیت‌های build و deploy	سرعت تغییر بالا با ریسک رگرسیون کمتر
پول و مصرف سمت سرور	هر قابلیت جدید می‌تواند بدون نگرانی از دستکاری کلاینت، شارژ شود

دارایی‌های آماده اما بلااستفاده:

- **گیت‌وی AI:** fallback، circuit breaker، مخفی‌سازی مدل و اعتبار — فقط اتصال نمی‌خواهد.
- **چندردیفی:** `ProviderConfig` schema چند پروفایل را می‌پذیرد، اما `activeProvider()` فقط جدیدترین را می‌گیرد؛ مسیریابی چندپروفایلی یک تغییر کوچک است.
- **اختیاری:** `refund()` آداپتورهایی که بازپرداخت برنامه‌ای ندارند، همان چرخه فعلی را نگه می‌دارند.
- **متر زمان:** برای ایجنت‌های صوتی/جلسه‌ای آماده است؛ فعال‌سازی آن یک تنظیم ادمین است.
- **`ClientError` :** داده خام کافی برای تبدیل به تحلیل کیفیت/اولویت باگ دارد.
- **`agentScope` :** امکان محدودکردن ارائه‌دهنده به زیرمجموعه ایجنت‌ها؛ پایه مسیریابی per-agent.

۸.۱ منطق ترتیب

این نقشه بر سه اصل استوار است:

۱. **اول ریسک را برطرف کن، بعد عمق بساز.** تا وقتی پول، پایش و پشتیبانی قابل اعتماد نیست، اضافه‌کردن RAG ارزش را افزایش نمی‌دهد؛ ریسک را افزایش می‌دهد.

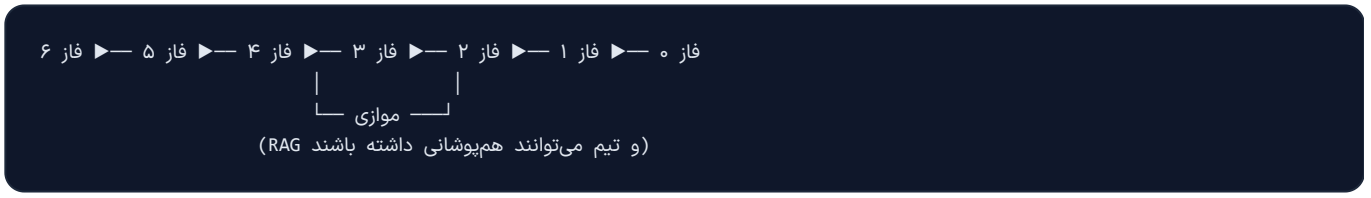
۲. **هر فاز باید یک خروجی قابل فروش داشته باشد.** فازها لیست آرزو نیستند؛ هر کدام یک «دروازه عبور» دارد.

۳. **عمق بهتر از پهنا می‌فروشد.** ۵۰ ایجنت عالی، بیشتر از ۲۶۴ ایجنت متوسط فروش می‌برد.

پاسخ کوتاه به «چند مرحله؟»: ۶ مرحله اصلی، به‌همراه یک فاز صفر تثبیت. ترتیبی حدود ۱۸ ماه تا پایان فاز ۵؛ با موازی‌سازی واقع‌بینانه ۱۲ تا ۱۵ ماه. فاز ۶ یک افق ۱۸ تا ۲۴ ماهه است.

۸.۲ نمای کلی فازها

فاز	نام	زمان تقریبی	هدف اصلی	خروجی کلیدی	دروازه عبور
۰	تثبیت و لانچ تجاری	۲ تا ۴ هفته	قابل اعتماد کردن پول و عملیات	پایش، بکاپ، E۲E، کپی واقعی، ۵۰ ایجنت بازبینی‌شده	۱۰۰ تراکنش موفق، ۹۹.۹٪ آپ‌تایم، بازیابی آزمایشی
۱	موتور مدل و اقتصاد مصرف	۶ تا ۸ هفته	چندارائه‌دهنده، مقاوم، هزینه‌شناس	گیت‌وی وصل‌شده، مسیریابی، دفتر هزینه، کش، eval	۳۰ روز گیت‌وی به‌عنوان مسیر اصلی، هزینه ۲۵٪ کمتر
۲	میز کار ایجنت‌ها	۱۰ تا ۱۲ هفته	از چت به «کار انجام‌شده»	فایل، RAG، ابزار، artifact، حافظه، ارزیابی	۲۰٪ جلسات از فایل/ابزار، کیفیت بالاتر از baseline
۳	تیم و سازمان	۸ تا ۱۰ هفته	فروش B۲B	سازمان، صندلی، SSO، لاگ حسابرسی، صورتحساب	۵ پایلوت سازمانی، NRR > ۱۱۰٪
۴	اقتصاد خالقان و API	۱۰ تا ۱۴ هفته	عرضه مقیاس‌پذیر	ساخت ایجنت، بازبینی، تقسیم درآمد، API/SDK	۵۰ خالق، ۱۵۰ ایجنت، تخلف < ۲٪
۵	مقیاس، اعتماد و منطقه	۱۲ تا ۱۶ هفته	آمادگی سازمانی و منطقه‌ای	Multi-region، صف، SSR، WAF، DR، عربی	۹۹.۹۵٪ برای ۹۰ روز، failover موفق
۶	سیستم‌عامل کار دانشی	۱۸ تا ۲۴ ماه	ایجنت‌های بلندمدت و خودکار	Orchestration، یکپارچه‌سازی، MCP، حکمرانی	۱۰۰ گردش‌کار سازمانی با ROI اثبات‌شده



۸.۳ فاز ۰ — تثبیت و لانچ تجاری (۲ تا ۴ هفته)

هدف: محصولی که می‌توان با پول واقعی به کاربر واقعی فروخت.

فنی:

- چک‌لیست محیط production: `DATABASE_URL`، `DIRECT_URL`، `PROVIDER_KEY_SECRET`، `PAYMENT_PROVIDER`، `SMS_PROVIDER`، دامنه، `COOKIE_SECURE`.
- بکاپ خودکار Postgres + آزمون بازیابی واقعی (RTO/RPO مشخص).
- پایش: Sentry یا معادل خودمیزبان برای خطای سرور و فرانت؛ request ID؛ هشدار ۵xx، خطای پرداخت، صف بازپرداخت.
- هشدار مصرف/هزینه: اگر مصرف یک کاربر یا ایجنت از آستانه گذشت، اطلاع.

- E2E مرورگر: ثبت‌نام → خرید → چت → بازپرداخت؛ آزمون بار حداقلی برای `/api/chat/stream` .
- بازبینی امنیتی: وابستگی‌ها، اسکن secret، CSP report-only، چک‌لیست OWASP.
- گزارش روزانه تطبیق تراکنش‌ها با درگاه.
- حذف/برچسب‌زدن rating و sales ساختگی؛ اصلاح کپی‌های متناقض.
- رفع باگ `agent.category` در چت انگلیسی.
- Pre-render ساده برای ۲۶۴ صفحه ایجنت (حتی با یک سرویس Prerender) + structured data + تصویر OG اختصاصی هر ایجنت.

محصولی:

- بازبینی تخصصی ۵۰ ایجنت پرتقاضا؛ بقیه با برچسب «Beta».
- آنبوردینگ اولین اجرا: توضیح پیش‌نمایش، انتخاب پرامپت، هزینه تقریبی.
- کانال پشتیبانی، وضعیت سرویس، پاسخ به سؤالات متداول پرداخت/بازپرداخت.
- سیاست محتوا و استفاده منصفانه.

دروازه عبور:

- ۱۰۰ تراکنش موفق بدون حادثه تسویه.
- ۹۹.۹٪ آپ‌تایم در ۳۰ روز.
- بازیابی از بکاپ با RTO < ۱ ساعت و RPO < ۱۵ دقیقه.
- SLA بازپرداخت < ۴۸ ساعت.
- هیچ کپی متناقضی در مسیر خرید باقی نماند.

تیم: ۲ مهندس + ۱ محتوا/کیفیت.

۸.۴ فاز ۱ — موتور مدل و اقتصاد مصرف (۶ تا ۸ هفته)

هدف: قطعی یک ارائه‌دهنده، محصول را زمین نزند؛ و بدانید هر گفت‌وگو چقدر حاشیه دارد.

فنی:

- اتصال `gateway` به‌عنوان آداپتور ارائه‌دهنده در `server/src/provider/` ؛ حفظ مسیر مستقیم به‌عنوان fallback.
- مسیریابی مدل بر اساس ایجنت/کاربر: `agent-pro` برای کارهای پیچیده، `agent-basic` برای پاسخ‌های سریع/ارزان.
- fallback زنجیره‌ای، circuit breaker، مهلت سازگار با سقف ۶۰ ثانیه Vercel.
- استریم از گیت‌وی (یا حداقل پاسخ کامل + نمایش تدریجی)؛ بدون شکستن قرارداد SSE فعلی.
- **دفتر هزینه:** نگاشت `UsageEvent` به هزینه واقعی ارائه‌دهنده؛ حاشیه به تفکیک ایجنت/کاربر/روز.
- کش پاسخ امن (فقط برای پرامپت‌های تکراری و بدون داده حساس)؛ prompt caching.
- بودجه سخت هر درخواست و هر کاربر در روز؛ هشدار مصرف غیرعادی.

- eval پایه: مجموعه ۵۰ پرامپت طلایی برای هر حوزه پرتقاضا؛ مقایسه مدل‌ها و نسخه پرسونا.
- A/B آزمایشی برای مدل/قیمت (با کنترل کیفیت).

محصولی:

- نمایش «حالت سریع/کیفیت» اگر تفاوت معنادار است.
- تخمین مصرف قبل از ارسال برای پیام‌های بلند.
- هشدار موجودی کم و پیشنهاد شارژ.
- شفافیت در مورد محدودیت‌ها: «پاسخ بر اساس پرسونا، بدون جست‌وجوی وب».

دروازه عبور:

- گیت‌وی ۳۰ روز مسیر اصلی باشد؛ سهم خطای ناشی از ارائه‌دهنده < ۱٪.
- هزینه هر ۱٬۰۰۰ توکن ۲۵٪ کاهش یابد (یا حاشیه ۱۰ واحد بهتر شود).
- صفر موجودی منفی؛ صفر شارژ بدون `UsageEvent` .
- p۹۵ اولین توکن < ۴ ثانیه.

تیم: ۲ تا ۳ مهندس + ۱ DevOps/ML.

۸.۵ فاز ۲ — میز کار ایجنت‌ها (۱۰ تا ۱۲ هفته)

هدف: ایجنت از «مشاور متنی» به «مجری کار» تبدیل شود.

فنی:

- آپلود فایل: object storage (S۳/R۲)، سقف حجم/نوع، اسکن ویروس، چرخه عمر فایل.
- استخراج متن: PPTX ،XLSX ،DOCX ،PDF، تصویر (OCR)؛ نرمال‌سازی فارسی.
- chunking + embedding + pgvector؛ RAG با citation و کنترل دسترسی به تفکیک کاربر/سازمان.
- ابزارها: جست‌وجوی وب، اجرای کد در sandbox، خواندن API ،URLهای مجاز؛ allowlist و بودجه.
- artifact: تولید سند/اسلاید/شیت قابل دانلود؛ نسخه‌بندی و لینک اشتراک.
- حافظه: خلاصه گفت‌وگو، حافظه کاربر/سازمان، fact pinning؛ ساخت prompt با بودجه.
- نسخه‌بندی پرسونا و پرامپت؛ registry؛ eval regression در CI.
- guardrail: PII redaction، prompt injection detection، سیاست محتوا.

محصولی:

- «پروژه» به‌جای «گفت‌وگو»: هر پروژه فایل، دستورالعمل و خروجی دارد.
- قالب‌های گردش‌کار چندایجنتی (مثلاً بریف → کپی → بازبینی).
- خروجی قابل دانلود PDF/DOCX/PPTX و اشتراک‌گذاری.
- PWA: نصب، نوتیفیکیشن، حالت آفلاین محدود.

- ورودی صوتی (اختیاری).

دروازه عبور:

- ۲۰٪ جلسات پرداخت‌شده از فایل یا ابزار استفاده کنند.
- کیفیت پاسخ با eval بهتر از baseline؛ بدون افزایش شکایت.
- D۳۰ retention حداقل ۱۰ واحد بهبود.
- ۲۰٪ ARPU بالاتر در گروه آزمایش.

تیم: ۳ تا ۴ مهندس + ۱ ML/Data.

۸.۶ فاز ۳ — تیم و سازمان (۸ تا ۱۰ هفته)

هدف: فروش به سازمان، نه فقط فرد.

فنی:

- `Organization` ، `Membership` ، نقش‌ها (Owner/Admin/Member)، دعوت با ایمیل/پیامک.
- کیف پول مشترک + سقف هر عضو + سهمیه تیمی.
- SSO: SAML/OIDC؛ SCIM در فاز بعد.
- Audit log: چه کسی، چه ایجنتی، چه زمانی، چه مصرفی.
- صورتحساب: فاکتور، VAT، شماره اقتصادی، پرداخت سازمانی؛ تطبیق دستی/خودکار.
- داده و حریم: export، retention policy، حذف حساب سازمانی، DPA.
- پنل ادمین سازمانی: مصرف هر عضو/ایجنت، هشدار بودجه.

محصولی:

- کتابخانه مشترک تیم؛ گفت‌وگوهای قابل اشتراک (opt-in).
- قالب‌های سازمانی؛ approval workflow برای خروجی حساس.
- آنبوردینگ سازمانی و صفحه امنیت.

دروازه عبور:

- ۵ پایلوت سازمانی فعال.
- بازبینی امنیتی/حقوقی پاس شود.
- NRR > ۱۱۰٪ در پایلوت‌ها.
- زمان چرخه فروش < ۴۵ روز.

تیم: ۴ مهندس + ۱ فروش/حل‌وساز.

۸.۷ فاز ۴ — اقتصاد خالقان و API (۱۰ تا ۱۴ هفته)

هدف: عرضه بدون هزینه خطی رشد کند؛ توسعه‌دهنده بتواند بسازد.

فنی:

- Agent Builder بدون کد: پرسونا، پرامپت، ابزار، سیاست مدل، قیمت، نسخه.
- محیط sandbox برای تست ایجنت قبل از انتشار.
- صف بازبینی: کیفیت، سیاست محتوا، امنیت، eval.
- داشبورد خالق: فروش، مصرف، تقسیم درآمد ۷۰/۳۰، تسویه، مالیات.
- API عمومی: کلید، rate limit، scope، مصرف، OpenAPI، SDK، webhook.
- جست‌وجوی ترکیبی (BM۲۵ + embedding)؛ رتبه‌بندی و توصیه.
- نظرات تأییدشده خریدار؛ حذف rating ساختگی.
- moderation و تشخیص سوءاستفاده.

محصولی:

- برنامه خالقان، ایجنت ویژه، باندل، affiliate.
- «ایجنت به‌مثابه API» برای کسب‌وکار.
- صفحات عمومی خالق.

دروازه عبور:

- ۵۰ خالق فعال، ۱۵۰ ایجنت منتشرشده.
- ۳۰٪ درآمد از عرضه بیرونی (هدف ۱۲ ماهه).
- تخلف سیاست < ۲٪.
- پوشش نظر > ۳۰٪ خریدها.

تیم: ۴ تا ۵ مهندس + ۱ عملیات محتوا.

۸.۸ فاز ۵ — مقیاس، اعتماد و منطقه (۱۲ تا ۱۶ هفته)

هدف: آمادگی برای ۱ میلیون کاربر فعال و بازار منطقه‌ای.

فنی:

- Multi-region یا حداقل multi-AZ؛ read replica؛ connection pooling.
- صف/کار پس‌زمینه (BullMQ/SQS) برای ایمیل، گزارش، پردازش فایل، همگام‌سازی.
- OpenTelemetry: trace، metric، log؛ SLO و error budget.
- SSR/ISR برای ۲۶۴ صفحه + ۱۸ صفحه حوزه؛ edge cache؛ Core Web Vitals.

- bot protection، WAF، چرخش KMS/HSM، secret، آزمون نفوذ مستقل.
- DR: PITR، RTO/RPO، تمرین chaos.
- بومی‌سازی: عربی (RTL)، زبان‌های منطقه؛ multi-currency؛ درگاه‌های محلی.

محصولی:

- اپ موبایل (React Native/Expo) یا PWA پیشرفته.
- ایجنت‌های سازمانی با دانش خصوصی؛ گزینه VPC/on-prem.
- بسته‌های منطقه‌ای و شراکت محلی.

دروازه عبور:

- ۹۹.۹۵٪ آپ‌تایم برای ۹۰ روز.
- failover منطقه‌ای موفق.
- p۹۵ < ۲ ثانیه برای صفحات کلیدی.
- ۳۰٪ درآمد از منطقه (هدف).

تیم: ۵ تا ۷ مهندس + SRE.

۸.۹ فاز ۶ — سیستم‌عامل کار دانشی (۱۸ تا ۲۴ ماه)

هدف: از «بازار ایجنت» به «سیستم‌عامل نیروی کار دانشی».

فنی:

- ایجنت‌های بلندمدت/زمان‌بندی‌شده؛ trigger رویداد؛ human-in-the-loop.
- Orchestration چندایجنتی: planner/executor، حافظه مشترک، بودجه.
- بازار ابزار و اتصال‌ها: CRM، Notion، Slack، Microsoft ۳۶۵، Google Workspace، MCP.
- پلتفرم ارزیابی؛ fine-tune/distillation؛ مدل محلی برای هزینه/حریم.
- حکمرانی: audit، guardrail، policy engine، حذف داده.

محصولی:

- «هم‌تیمی دیجیتال» با نقش، KPI و تحویل کار.
- راه‌حل‌های عمودی: آژانس بازاریابی، حقوق، سلامت، مالی.
- قیمت‌گذاری مبتنی بر نتیجه.

دروازه عبور:

- ۱۰۰ گردش‌کار سازمانی با ROI قابل اندازه‌گیری.
- هزینه مدل < ۲۰٪ درآمد.

- ۹۹.۹۹٪ برای مشتریان سازمانی.

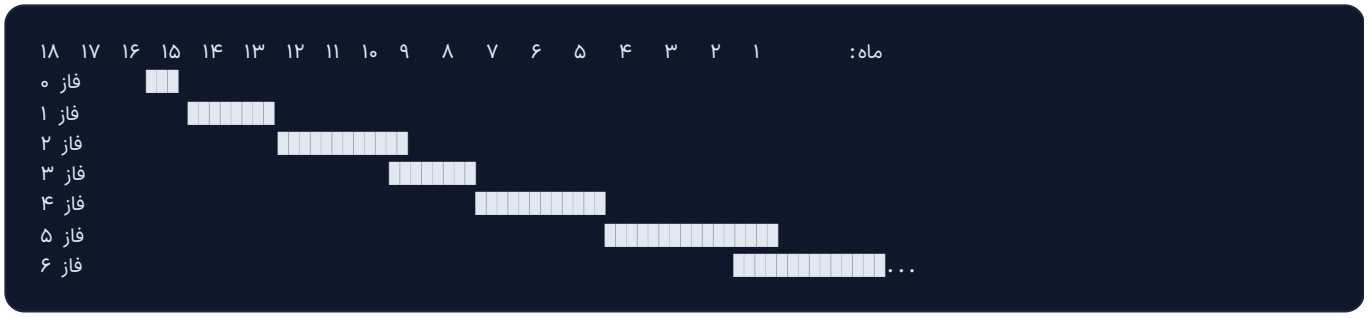
تیم: ۸ تا ۱۲ نفر.

۸.۱۰ چه چیزی موازی پیش می‌رود؟

اینها را نباید به «پایان فاز» موکول کرد؛ در تمام فازها جریان دارند:

جریان دائمی	کار
کیفیت محتوا	بازبینی ۵۰ ایجنت پرتقاضا، نسخه‌بندی پرسونا، eval
اعتماد	شفافیت قیمت، نظرات واقعی، سیاست بازپرداخت، صفحه امنیت
پایش	هشدار، داشبورد هزینه/تبدیل، SLO
امنیت	اسکن وابستگی، آزمون نفوذ دوره‌ای، چرخش کلید
رشد	سئو، محتوا، ارجاع، شراکت
پشتیبانی	بازخورد، حلقه بهبود محصول، SLA

۸.۱۱ نمای زمانی



تخمین‌ها برای تیم ۳ تا ۵ نفره است. با تیم ۲ نفره، ضرب در ۱.۵ تا ۲. با تیم ۸ نفره و موازی‌سازی، می‌تواند ۲۵ تا ۳۵ درصد کوتاه‌تر شود — به شرط وجود مالک محصول و QA.

۹ اولویت‌بندی و تصمیم‌های فنی

۹.۱ ماتریس اثر / تلاش

خانه	اقدام‌ها
Quick win (اثر بالا، تلاش کم)	حذف rating ساختگی؛ اصلاح کپی قیمت؛ رفع باگ دسته چت؛ Sentry؛ هشدار پرداخت؛ pre-render صفحات ایجنت؛ نظرات خریدار؛ داشبورد هزینه ساده
Big bet (اثر بالا، تلاش زیاد)	اتصال گیت‌وی و مسیریابی مدل؛ RAG/فایل/ابزار؛ تیم و SSO؛ بازار خالقان؛ API عمومی
Fill-in (اثر کم، تلاش کم)	پایه؛ ارجاع؛ حالت تاریک؛ بهبود ۴۰۴؛ جست‌وجوی بهتر PWA
فعلاً نه (اثر کم/نامعلوم، تلاش زیاد)	مدل بنیادی خودی؛ اپ نیتیو کامل قبل از PMF؛ ساخت ایجنت بدون کد قبل از عرضه؛ multi-region قبل از ۱۰۰هزار کاربر

۹.۲ بساز یا بخر

قابلیت	تصمیم پیشنهادی	دلیل
کیف پول/مالکیت/ دفتر تراکنش	**بساز**	هسته تمایز و اعتماد؛ وابستگی به SaaS ریسک است
کاتالوگ/پرسونا	**بساز + بازبینی انسانی**	مزیت بومی؛ تولید صرفاً ماشینی کیفیت را خراب می‌کند
احراز هویت OTP	**بساز (فعلی) یا خرید**	فعلی ساده و امن است؛ در مقیاس سازمانی، IdP بخر
پرداخت	**بخر/آداپتور**	زرین‌پال/استرایپ؛ نباید درگاه بسازید
پیامک	**بخر**	کاوه‌نگار؛ زیرساخت مخابراتی نیست
RAG/Vector	**بساز روی pgvector**	داده کم، هزینه پایین؛ از سرویس جدا فقط در مقیاس
Observability	**بخر**	اتلاف است APM ؛ ساختنSentry/Datadog
صف/Job	**بخر/مدیریت‌شده**	؛ نگهداری صف، تمایز نیستSQS/BullMQ
CDN/WAF	**بخر**	؛ امنیت لبه تخصصی استCloudflare/Vercel
Eval	**بساز + ابزار**	داده طلایی شما، مزیت است
مدل پایه	**بخر/اجاره**	ساخت مدل بنیادی برای این مرحله توجیه ندارد

۹.۳ اصول معماری که باید حفظ شوند

۱. **سرور، منبع حقیقت است.** قیمت، مالکیت، مصرف و کلید مدل هرگز از کلاینت پذیرفته نمی‌شوند.

۲. **پول یک دفتر است، نه یک عدد.** هر حرکت، رکورد و دلیل دارد.

۳. **هر شارژ، یک رویداد مصرف دارد.** بدون `UsageEvent`، کسر ممنوع.

۴. **ارائه‌دهنده مدل قابل تعویض است.** هیچ منطق محصولی به یک برند مدل گره نخورد.

۵. **کاتالوگ، کد است.** تولید، بازبینی و گیت دارد.

۶. **در زمان درخواست، فایل نخوان.** state در Postgres؛ کاتالوگ در build.

۷. **پول: fail closed. دسترس‌پذیری: fail open با هشدار.** موجودی ناکافی = رد؛ Redis قطع = عبور با لاگ.

۸. **بومی‌سازی یک قید اول‌کلاس است، نه ترجمه.** RTL، ارقام، لحن، پول.

۹. **گیت جای امید را بگیرد.** build، deploy check، eval.

۱۰. **هر قابلیت جدید، یک دروازه و یک معیار دارد.**

۹.۴ اهداف غیرعملکردی پیشنهادی

حوزه	هدف پایه (پس از فاز ۰)	هدف ۱۲ ماه
آپ‌تایم	۹۹.۹٪	۹۹.۹۵٪
API پاسخ p۹۵	< ۸۰۰ms	< ۵۰۰ms
اولین توکن چت p۹۵	< ۵s	< ۳s
نرخ موفقیت پرداخت	> ۹۵٪	> ۹۷٪
نرخ خطای سرور	< ۱٪	< ۰.۵٪
RTO / RPO	مشخص نیست	< ۱h / < ۱۵m
پوشش تست واحد مسیرهای پول	بازبینی‌نشده	> ۸۰٪
دسترس‌پذیری	بازبینی‌نشده	WCAG ۲.۲ AA
امنیت	هدرها/CSP	OWASP ASVS L۲
حاشیه ناخالص	نامعلوم	> ۵۵٪ با دفتر هزینه

۱۰ سنجه‌ها

۱۰.۱ ستاره شمالی

تعداد «کارهای تکمیل‌شده با کیفیت قابل تحویل» در ماه.

چرا نه «تعداد پیام»؟ چون پیام زیاد می‌تواند نشانه سردرگمی باشد. چرا نه «درآمد»؟ چون درآمد نتیجه است، نه جهت. «کار تکمیل‌شده» یعنی کاربر با یک خروجی قابل استفاده از ایجنت بیرون آمده است.

۱۰.۲ سه لایه سنجه

لایه	سنجه	تعریف
فنی	uptime، p۹۵ latency، error rate، payment success، fallback rate، cost per task، token estimation error، crash-free sessions، MTTR	سلامت سیستم
محصول	activation (اولین چت < ۱۰ دقیقه)، preview→purchase، DV/D۳۰ retention، refund rate، NPS، file/tool adoption، task success rate	ارزش برای کاربر
کسب‌وکار	MRR/ARR، ARPU، CAC، LTV/CAC، gross margin، churn، B۲B pipeline، revenue per agent	پایداری

۱۰.۳ قیف پیشنهادی

```
بازدید صفحه اصلی
  → جست‌وجو/فیلتر
  → مشاهده صفحه ایجنت
  → پیش‌نمایش (۳ پیام)
  → کلیک خرید
  → پرداخت موفق
  → اولین چت پس از خرید
  → خرید دوم / تمدید پلن
```

برای هر مرحله، نرخ تبدیل و زمان را ثبت کنید. امروز این قیف به‌صورت کامل ابزارگذاری نشده است؛ **فاز ۰ باید حداقل رویدادهای قیف را بگذارد.**

۱۱ ریسک‌ها

ریسک	احتمال	اثر	کاهش	نشانه هشدار
دسترسی به مدل/ تحریم	متوسط	بالا	گیت‌وی چندمسیره، Ollama محلی، اعتبار پیش‌پرداخت، تعویض ارائه‌دهنده	خطای ۴۰۱/۴۲۹ مکرر؛ افزایش latency
نوسان ارز	بالا	متوسط	بازنگری فصلی قیمت، فروش بسته توکن، پوشش طبیعی خط دلاری	افت حاشیه ماهانه
کیفیت فارسی	متوسط	بالا	بازبینی ۵۰ ایجنت، eval، بازخورد، نسخه‌بندی	افزایش بازپرداخت/شکایت

ریسک	احتمال	اثر	کاهش	نشانه هشدار
Social proof ساختگی	بالا (اگر حذف نشود)	بالا	حذف یا جایگزینی با نظر واقعی	شکایت «امتیازها واقعی نیست»
پرداخت/تسویه	متوسط	بالا	تست با PSP ساختگی، تطبیق روزانه، idempotency	تراکنش pending قدیمی
امنیت (نشت کلید/OTP)	کم	بسیار بالا	AES-GCM، هش، rate limit، چرخش کلید، آزمون نفوذ	لاگ دسترسی غیرعادی
Prompt injection/RAG	متوسط (در فاز ۲)	بالا	sandbox، allowlist، جداسازی دستور و داده، redaction	خروجی حاوی دستور سیستمی
وابستگی به Vercel/ ۶۰s	متوسط	متوسط	گیت‌وی استریم، صف، گزینه runtime جایگزین	قطع استریم طولانی
تمرکز کاتالوگ	بالا	متوسط	تنوع حوزه، عرضه خالقان، ایجنت‌های ایرانی	افت تقاضای مهندسی
قانون/انطباق	متوسط	متوسط	شرایط شفاف، سیاست محتوا، حریم، برچسب AI	تغییر مقررات
وابستگی به فرد کلیدی	متوسط	بالا	مستندسازی، مالکیت کد، تیم‌سازی	کندی تحویل

۱۲ نقشه ۹۰ روزه

بازه	تمرکز	خروجی‌ها	مالک
روز ۱ تا ۳۰	تثبیت لانچ	محیط production؛ Sentry؛ بکاپ/بازیابی؛ حذف rating ساختگی؛ اصلاح کپی؛ رفع باگ چت؛ pre-render ۲۶۴ صفحه؛ ۵۰ ایجنت بازبینی‌شده؛ E۲E خرید→چت	مهندسی + محتوا
روز ۳۱ تا ۶۰	اقتصاد و پایداری	اتصال گیت‌وی؛ دفتر هزینه؛ مسیریابی مدل؛ داشبورد حاشیه؛ آزمون بار؛ هشدار مصرف؛ PWA پایه	مهندسی + ML
روز ۶۱ تا ۹۰	عمق و رشد	RAG MVP (PDF/DOCX)؛ نظرات؛ B۲B خریدار؛ برنامه ارجاع؛ ۳ پایلوت آزمایش قیمت/پلن؛ محتوای سئو	محصول + رشد

معیار موفقیت ۹۰ روز:

- ۳۰۰ تراکنش موفق، نرخ موفقیت پرداخت > ۹۵٪.
- ۹۹.۹٪ آپ‌تایم، p۹۵ اولین توکن < ۴ ثانیه.
- ۲۰٪ جلسات پرداخت‌شده با فایل (RAG MVP).
- ۳ پایلوت سازمانی امضاشده.
- حاشیه ناخالص قابل محاسبه (نه حدس) برای ۱۰ ایجنت پرتقاضا.

۱۳ جمع‌بندی

۱. **AgentFA یک محصول کامل «فروشگاه + موتور اجرا» است، نه یک دمو.** ۲۶۴ ایجنت، کیف پول، پرداخت، مالکیت، چت استریم، ادمین و دوزبانگی دارد.

۲. **قوی‌ترین بخش آن، لایه اعتماد است:** پول سمت سرور، تسویه با تأیید درگاه، OTP امن، کلید رمزنگاری‌شده، مصرف قابل حسابرسی.

۳. **ضعیف‌ترین بخش آن، عمق اجراست:** یک ارائه‌دهنده، بدون فایل/RAG/ابزار/تیم/API. امروز «مشاور متنی» است، نه «کارگزار».

۴. **ظرفیت توسعه بالا است، اما ترتیب مهم است:** اول تثبیت و اقتصاد (فاز ۰ و ۱)، بعد عمق (۲)، بعد سازمان (۳)، بعد عرضه (۴)، بعد مقیاس (۵) و در نهایت سیستم‌عامل کار (۶).

۵. **اگر فقط یک کار انجام شود:** کیفیت ۵۰ ایجنت پرتقاضا + اتصال گیت‌وی + دفتر هزینه. این سه، هم اعتماد می‌سازند هم حاشیه را قابل مدیریت می‌کنند.

جمله پایانی:

> AgentFA امروز یک بازار ایجنت با زیرساخت تراکنش بالغ است. مرحله بعد، تبدیل «چت با متخصص» به «تحویل کار توسط متخصص» است؛ و این تبدیل، با فایل، ابزار، حافظه و ارزیابی آغاز می‌شود — نه با ایجنت بیشتر.

الف سطح API

گروه	مسیرها
Auth	`POST /api/auth/otp/start` · `POST /api/auth/otp/verify` · `POST /api/auth/logout` · `GET /api/auth/me`
Catalog	`GET /api/catalog` · `GET /api/agents/:id/persona` (قفل‌شده)
Wallet	`GET /api/wallet` · `POST /api/wallet/topup` · `POST /api/wallet/plan` · `GET /api/wallet/transactions` · `GET /api/wallet/usage`
Agents	`GET /api/agents/owned` · `POST /api/agents/:id/buy` · `POST /api/agents/:id/refund`
Chat	`GET /api/chat/preview` · `POST /api/chat/stream` · `GET /api/chat/conversations` · `GET /api/chat/conversations/:id` · `POST /api/chat/conversations` · `DELETE /api/chat/conversations/:id`
Payments	`GET /api/payments/:id` · `GET/POST /api/payments/callback/:provider` · `POST /api/payments/webhook/:provider`
Admin	`GET /api/admin/stats` · `GET /api/admin/refunds` · approve/reject · provider config/test · `GET /api/admin/client-errors`
Account	`GET /api/account` · `DELETE /api/account` · `POST /api/account/phone/start` · `POST /api/account/phone/verify`
Pricing	`GET /api/pricing`
Health	`GET /api/health`
Client errors	`POST /api/client-errors`

ب مدل داده

جدول	کلید/فیلدهای مهم	نقش
User	phone یکتا، role	هویت
Session	tokenHash یکتا، expiresAt	نشست
LoginCode	consumedAt ، expiresAt ، attempts ، codeHash	OTP
Wallet	plan ، دو موجودی، دو سهمیه، دوره	کیف پول
Transaction	orderId یکتا، providerToken یکتا، refId یکتا، نوع/وضعیت/مبلغ	دفتر پول
Entitlement	(userId, agentId) یکتا، revokedAt	مالکیت
UsageEvent	providerModel ، estimated ، seconds ، tokens	ریز مصرف
Agent	slug یکتا، price ، division	کاتالوگ
Persona	agentId کلید، body	متن کامل پرسونا
Division	sortOrder ، labelFa ، label ، slug	حوزه
PreviewUsage	(userId, agentId) کلید، used	پیش‌نمایش
Conversation	totalTokens ، title ، agentId ، userId	گفت‌وگو
Message	tokens ، content ، role ، conversationId	پیام
ProviderConfig	meter ، model ، apiKeyCipher ، baseUrl ، agentScope	تنظیم مدل
RateLimit	(key, windowStart) کلید، count	محدودیت نرخ
ClientError	fingerprint یکتا، count ، lastSeenAt	خطای مرورگر

ج نقشه فایل‌ها

مسیر	نقش
`server/src/app.ts`	ساخت Fastify، ثبت مسیرها، parser، cookie، CORS خام
`server/src/routes/chat.ts`	چت استریم، مالکیت/پیش‌نمایش، بودجه، ذخیره
`server/src/provider/stream.ts`	فراخوانی مدل، SSE، timeout، تخمین توکن
`server/src/provider/crypto.ts`	رمزنگاری کلید ارائه‌دهنده
`server/src/payments/*`	قیمت، آداپتورها، امضا، تسویه
`server/src/wallet.ts`	دوره، موجودی، کسر اتمی
`server/prisma/schema.prisma`	۱۶ جدول و قیدها
`agentfa-web/src/routes.tsx`	روتر، صفحه اصلی، بازار، جزئیات، داشبورد
`agentfa-web/src/pages/Chat.tsx`	چت، استریم، تاریخچه، خرید توکن UI
`agentfa-web/src/pages/Admin.tsx`	پنل ادمین
`agentfa-web/src/lib/i18n.tsx`	دیکشنری‌ها و RTL
`agentfa-web/src/lib/account.ts`	کلاینت API
`agentfa-web/scripts/generate-catalog.mjs`	تولید کاتالوگ
`agentfa-web/scripts/check-*.mjs`	گیت‌های i18n/catalog/routes
`gateway/`	FastAPI + LiteLLM
`api/index.ts`	ورودی Vercel، بازسازی URL
`scripts/check-deploy.mjs`	بررسی ۱۲گانه استقرار
`vercel.json`	Function، هدرها، rewrite

د واژه‌نامه

واژه	معنا
ایجنت (Agent)	پرسونای تخصصی با دامنه، فرایند و لحن مشخص که با مدل اجرا می‌شود
پرسونا (Persona)	متن کامل دستور/شخصیت ایجنت که فقط سمت سرور نگهداری می‌شود
حوزه (Division)	دسته‌بندی سطح بالا؛ ۱۸ حوزه
مالکیت (Entitlement)	حق دائمی کاربر برای استفاده از یک ایجنت
کیف پول (Wallet)	موجودی توکن/زمان + سهمیه + دوره
توکن	واحد مصرف متنی؛ ۲ توکن = ۱ تومان
اعتبار زمانی	واحد مصرف برای ایجنت‌های meter=time؛ ۵۰۰ تومان/دقیقه
پلن	سهمیه یک دوره ۳۰ روزه؛ نه اشتراک با تمدید خودکار
پیش‌نمایش	۳ پاسخ رایگان روی ایجنت خریداری‌نشده
SSE	Server-Sent Events؛ انتقال تدریجی پاسخ
RAG	بازیابی اطلاعات از فایل/دانش و تزریق به پرامپت
گیت‌وی	سرویس واسط FastAPI/LiteLLM برای چندارائه‌دهنده
تسویه (Settlement)	تبدیل پرداخت تأییدشده به مالکیت/شارژ
بازپرداخت (Refund)	برگشت پول با تأیید ادمین و ابطال مالکیت
Tenant/Org	سازمان مشتری با کاربران، کیف پول و سیاست مشترک (آینده)

۵ منابع، مفروضات و پرسش‌های باز

منابع اصلی

- `README.md` — کورپوس ایجنت‌ها و مجوز.
- `agentfa-web/README.md` — SPA، i۱۸n، استقرار، گیت‌ها.
- `server/README.md` — API، OTP، پرداخت، Vercel.
- `server/BILLING.md` — قیمت، کیف پول، تراکنش، بازپرداخت.
- `gateway/README.md` — گیت‌وی، fallback، امنیت، محدودیت‌ها.
- `docs/pitch/AgentFA-Technical-Overview-fa.md` — نمای فنی.
- `docs/pitch/AgentFA-OnePager-fa.md` — یک‌صفحه‌ای.
- `docs/pitch/AgentFA-Investor-Deck-fa.md` — دِک و نقشه راه.
- `server/prisma/schema.prisma` — مدل داده.
- `vercel.json` — استقرار، rewrite، هدرها.
- `scripts/check-deploy.mjs` — ۱۲ بررسی استقرار.

مفروضات سند

- snapshot کد در commit `104cfd4` مبنا است؛ تغییرات بعدی می‌تواند این توصیف را تغییر دهد.
- اعداد بازار/درآمد/حاشیه از اسناد pitch نقل شده‌اند و «هدف» هستند، نه داده حسابرسی‌شده.
- تست‌ها در این محیط اجرا نشدند (محدودیت sandbox)؛ وجود فایل‌ها و توصیف CI مبنا است.
- وضعیت «مرچنت/پنل پیامکی» به محیط استقرار بستگی دارد؛ کد آداپتور آماده است.

پرسش‌های باز برای تصمیم‌گیری

۱. **اولویت ۹۰ روز:** رشد (سئو/ارجاع) یا عمق (RAG/فایل) یا سازمانی (تیم/SSO)؟

۲. **مدل قیمت‌گذاری:** آیا مصرف باید هزینه واقعی + حاشیه باشد، یا قیمت ثابت ساده بماند؟

۳. **مالکیت کاتالوگ:** چه میزان از ۲۶۴ پرسونا باید بازبینی تخصصی و بومی‌سازی شود؟

۴. **برنامه خالقان:** ۷۰/۳۰؟ کیفیت‌سنجی چگونه؟ مسئولیت محتوا با کیست؟

۵. **سازمانی:** اولین عمودی کدام است؟ بازاریابی، حقوق، سلامت یا مالی؟

۶. **زیرساخت:** تا چه اندازه به Vercel وابسته بمانیم؟ آستانه مهاجرت چیست؟

۷. **داده:** سیاست نگهداری گفت‌وگو و فایل‌ها چیست؟ آیا مشتری سازمانی به عدم ذخیره نیاز دارد؟

۸. **برند:** `AgentFA` یا `AgentFa`؟ یکدست‌سازی در UI، متادیتا و اسناد لازم است.